



UNIVERSITAT OBERTA DE CATALUNYA (UOC)
MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS (*DATA SCIENCE*)

TRABAJO FINAL DE MÁSTER

ÁREA 4: RECONOCIMIENTO DE PATRONES Y VISIÓN COMPUTACIONAL PARA
CIENCIAS APLICADAS

Banco de Imágenes de Anotaciones de Aceras (BIAA) **Primeros pasos para disponer de recursos estructurados para la** **mejora de la monitorización y el mantenimiento del espacio público** **en Barcelona**

Autor: Joan Manel Ramírez Jávega
Tutor: Miguel Alejandro Ponce Proaño
Profesor: David Masip Rodo

Barcelona, 26 de diciembre de 2025

Copyright



Esta obra está sujeta a una licencia de Reconocimiento - NoComercial - SinObraDerivada
3.0 España de Creative Commons.

FICHA DEL TRABAJO FINAL

Título del trabajo:	Banco de Imágenes de Anotaciones de Aceras
Nombre del autor:	Joan Manel Ramírez Jávega
Nombre del colaborador/a docente:	Miguel Alejandro Ponce Proaño
Nombre del PRA:	David Masip Rodo
Fecha de entrega (mm/aaaa):	12/2025
Titulación o programa:	Máster de Ciencia de datos
Área del Trabajo Final:	Treball final de màster
Idioma del trabajo:	Español
Palabras clave	Deep Learning, Entornos urbanos, Visión computacional

Cita

Uno de los romanos observó desde cerca el muro, contó las piedras, echó cuentas mentalmente de lo que medía cada una a lo ancho, calculó la altura del muro ajustando la deducción cuanto pudo... (Tito Livio, *Ab Urbe Condita*, XXV.XXIII.11-12)

Agradecimientos

Es preciso agradecer el apoyo y el aliento brindado a este proyecto, con muchos cafés de por medio, a mis antiguos compañeros Gerardo Campos Rubio, Sara Berbis Fernández y Rubèn Valdeoriola Domínguez (Departamento de Obras y Mantenimiento, Dirección del Servicio de Licencias y Espacio Público, Distrito de Horta-Guinardó, Ayuntamiento de Barcelona). También merecen mi agradecimiento especial Francisco Ruiz Muñoz, Carmen Castaño González y Manuel Franco Mesas. De unos y otros aprendí mucho durante los años que trabajé en el Ayuntamiento de Barcelona y, en buena medida, este trabajo también se sostiene a los hombros de estos gigantes.

Del mismo modo, también quiero agradecer tanto a mis amigos, los doctores María Coto Sarmiento y Pau Valdés Matías; como a mis hermanos, los doctores Miguel Ramírez Jávega y Francisco Ramírez Jávega, por todos los buenos consejos y tiempo que me han dedicado para debatir, discutir y refinar este trabajo. Obviamente, cualquier error se deberá exclusivamente a la torpeza del autor.

Finalmente, quiero dar las gracias a mis padres, Francisco y María, pues es también gracias a su trabajo constante y silencioso que he llegado hasta aquí.

Abstract

This project focuses on the creation and exploitation of the so-called *Banco de Imágenes de Anotaciones de Aceras* (BIAA) or Sidewalk Annotation Image Bank, an image dataset collected and designed by the author for the study and improvement of urban public space through computer vision techniques. The project compiles, organizes, and annotates a collection of sidewalk images from Barcelona and its metropolitan area, with the aim of facilitating the training and validation of machine learning models oriented toward the detection of pavement anomalies.

The methodology combines the construction of a structured dataset with annotations in a standard format (COCO), the generation of instance segmentation masks, and the development of a reproducible pipeline for its use in classification and semantic segmentation tasks. In addition, metadata-related attributes such as timestamp, image resolution, and geographic coordinates are incorporated in order to enrich the analysis and ensure data traceability.

Keywords: Machine learning, Deep learning, Semantic segmentation, Instance segmentation, Neural networks, Computer vision, Public space maintenance, Urban planning, Urban environments, Sidewalks, Pavements, Monitoring, Anomaly detection, Image annotation, Image processing, Smart cities, Urban sustainability, Datasets, Benchmarks.

Resumen

El proyecto presente se centra en la creación y explotación del llamado *Banco de Imágenes de Anotaciones de Aceras* (BIAA), un conjunto de imágenes recopilado y diseñado por el autor para el estudio y la mejora del espacio público urbano mediante técnicas de visión computacional. El proyecto recopila, organiza y anota un conjunto de imágenes de aceras en Barcelona y su área metropolitana, con el objetivo de facilitar el entrenamiento y la validación de modelos de aprendizaje automático orientados a la detección de anomalías en el pavimento.

La metodología combina la construcción de un *dataset* estructurado con anotaciones en formato estándar (COCO), la generación de máscaras de segmentación de instancias y el desarrollo de un *pipeline* reproducible para su utilización en tareas de clasificación y segmentación semántica. Asimismo, se incorporan atributos relacionados con los metadatos como son la marca temporal, resolución de la imagen o sus coordenadas geográficas con el fin de enriquecer el análisis y garantizar su trazabilidad.

Palabras clave: Aprendizaje automático, Deep Learning, Segmentación semántica, Segmentación por instancias, Redes neuronales, Visión computacional, Mantenimiento de la vía pública, Urbanismo, Entornos urbanos, Aceras, Pavimentos, Monitorización, Detección de anomalías, Anotaciones de imágenes, Procesamiento de imágenes, Smart Cities, Sostenibilidad urbana, Conjuntos de datos, Benchmarks.

Índice general

Abstract	IX
Resumen	XI
Índice general	XIII
Lista de Figuras	XIX
Lista de Tablas	XXI
1. Introducción. Necesidades y enfoque	1
1. Propuesta de título	1
2. Palabras clave (keywords)	1
3. Resumen de la propuesta	1
4. Descripción de la propuesta	2
4.1. Justificación	2
4.2. Relevancia	3
4.3. Objetivos	4
5. Motivación personal	4
6. Planificación y plan de investigación del proyecto	5
7. Compromiso ético y global (CEG) y Objetivos de Desarrollo Sostenible (ODS)	6
8. Recapitulación y entregables	7
2. Estado del arte	9
1. El problema del mantenimiento de las aceras	10
1.1. El peatón	10
1.2. Competencias y procedimientos	11
1.3. Qué es una incidencia: del pavimento de las aceras a otras infraestructuras urbanas	14
1.4. Un problema yuxtapuesto: la conducción automática	17

2.	El problema de la visión computacional	18
2.1.	El paradigma COCO	18
2.2.	La clasificación de escenas	19
2.3.	La detección de objetos	20
2.4.	La segmentación semántica	21
2.5.	La segmentación por instancias	23
3.	El problema de la creación del conjunto de datos	25
3.1.	De las fuentes masivas de datos a la recopilación de datos sobre el terreno	26
3.2.	La anotación	29
4.	Resumen	31
3.	Materiales y métodos	33
1.	Recopilación de los datos del BIAA	34
2.	Comparación entre modelos preentrenados con Cityscapes y SAM (SA-1B) . . .	37
3.	La anotación	39
3.1.	Criterios de anotación del BIAA	40
3.2.	Preanotación con SAM	44
4.	Fine-tuning de DeepLabV3 preentrenado con Cityscapes usando datos del BIAA	45
4.	Resultados experimentales	47
1.	Resultados de la comparación entre modelos preentrenados con Cityscapes y SAM (SA-1B)	47
2.	Resultados del proceso de anotación	49
2.1.	Análisis exploratorio de los metadatos	50
2.2.	Efecto de la preanotación	51
3.	Entrenamiento con datos del BIAA	53
3.1.	Resultados cuantitativos (métricas)	53
3.2.	Resultados cualitativos de las predicciones	55
5.	Conclusiones	59
1.	Límites y perspectivas de futuro	60
	Bibliografía	62
	A. Cuestionario	69
	B. Figuras del análisis descriptivo del BIAA	81
	C. Figuras del análisis cualitativo de la comparación entre modelos	89

D. Figuras del experimento del ajuste de DeepLabV3 con el BIAA	99
---	-----------

Lista de Figuras

1.1.	Diagrama de cajas de la planificación del proyecto.	6
2.1.	Ejemplos de desperfectos en estructuras de hormigón, máscaras <i>ground truth</i> manuales y la predicción de las máscaras visualizadas por el <i>logit</i> de cada píxel, en este caso, por un modelo de arquitectura U-Net (Ahmadi et al. 2025).	15
2.2.	Ejemplo de la diferencia de los desperfectos observables en pavimentos modulares y asfálticos.	16
2.3.	Ejemplo de segmentación semántica con una red neuronal profunda entrenada con el <i>dataset</i> Cityscapes añadiendo algunas instancias adicionales para lograr su adaptación al dominio (Y.-H. Chen et al. 2017).	22
2.4.	Ejemplo de segmentación por instancias con SAM con muestras de los 23 <i>benchmarks</i> utilizados en la publicación original de Kirillov et al. (2023).	24
2.5.	Ejemplo ilustrativo de <i>data drift</i> , tal y como pone de relieve Anthony Sarkis (Sarkis 2024, pág. 23).	26
2.6.	Ejemplo de los límites de los datos recopilados en Google Street View.	29
3.1.	Distribución anual de las imágenes capturadas (<i>raw data</i>).	35
3.2.	Ejemplos del recorte aplicado a las imágenes (<i>raw data</i>) como preprocesamiento inicial.	35
3.3.	Mapa de la distribución geográfica de las imágenes capturadas (<i>raw data</i>).	36
3.4.	Trade-off descrito por A. Sarkis (Sarkis 2024, pág. 72) entre tiempo y calidad en la anotación.	39
3.5.	Demostración de los fenómenos de ocultación y truncado de objetos en una imagen (Sarkis 2024, pág. 71).	42
3.6.	Distribución de las instancias de cada clase anotada en el conjunto <i>ground truth</i>	43
3.7.	Priorización de las máscaras en el proceso de rasterización.	44
4.1.	Variancia y distribución del tiempo de anotación manual del conjunto <i>ground truth</i> , indicándose los cuartiles.	49

4.2. Variancia y distribución del tiempo de anotación manual del conjunto experimental, indicándose la estratificación intercuartiles del <i>ground truth</i>	50
4.3. Variancia y distribución del tiempo de posprocesamiento manual del conjunto experimental, indicándose la estratificación intercuartiles del <i>ground truth</i>	51
4.4. Frecuencias de las máscaras anotadas manualmente, las predicciones de SAM y de las que requirieron su eliminación, edición o adición.	52
4.5. Miniatura de las 6 imágenes seleccionadas para el análisis cualitativo.	56
A.1. Pregunta 36 (Typeform).	73
A.2. Pregunta 37 (Typeform).	74
A.3. Pregunta 38 (Typeform).	75
A.4. Pregunta 39 (Typeform).	75
A.5. Pregunta 40 (Typeform).	76
A.6. Pregunta 41 (Typeform).	76
A.7. Pregunta 42 (Typeform).	77
A.8. Pregunta 43 (Typeform).	77
A.9. Pregunta 44 (Typeform).	78
A.10. Pregunta 45 (Typeform).	79
A.11. Pregunta 46 (Typeform).	80
B.1. Frecuencias y proporción de la resolución de las imágenes una vez aplicado el recorte de preprocesamiento.	82
B.2. Distribución horaria de las imágenes desglosada por trimestres.	83
B.3. Treemap de la distribución geográfica de las imágenes capturadas (<i>raw data</i>) en el municipio de Barcelona.	84
B.4. Frecuencias y proporción de las instancias anotadas en función de su clase etiquetada en los subconjuntos de entrenamiento y validación.	85
B.5. Frecuencias y proporción de la resolución de imágenes en los subconjuntos de entrenamiento y validación.	86
B.6. Proporción del área rasterizada - número de píxeles- por cada clase en los subconjuntos de entrenamiento y validación.	87
C.1. Imágenes del BIAA segmentadas semánticamente por DeepLabV3+ entre las etiquetas <i>road</i> y <i>sidewalk</i> de Cityscapes.	90
C.2. Imágenes de los <i>benchmarks</i> BDD100K, Cityscapes y Mapillary Vistas segmentadas semánticamente con DeepLabV3+.	91
C.3. Imágenes del BIAA segmentadas semánticamente por HRNet entre las etiquetas <i>road</i> y <i>sidewalk</i> de Cityscapes.	92

C.4. Imágenes de los <i>benchmarks</i> BDD100K, Cityscapes y Mapillary Vistas segmentadas semánticamente con HRNet.	93
C.5. Imágenes del BIAA segmentadas semánticamente por Mask2Former entre las etiquetas <i>road</i> y <i>sidewalk</i> de Cityscapes.	94
C.6. Imágenes de los <i>benchmarks</i> BDD100K, Cityscapes y Mapillary Vistas segmentadas semánticamente con Mask2Former.	95
C.7. Muestra del resultado de la segmentación por instancias por SAM en modo <i>Segment Everything</i> con: imagen de alta resolución y configuración por defecto, imagen de alta resolución y configuración experimental, imagen con resolución reducida y configuración por defecto e imagen con resolución reducida y configuración experimental.	96
C.8. Segmentación por instancias de SAM en imágenes del BIAA con la parametrización experimental.	97
D.1. Desarrollo del entrenamiento con optimizador Adam y de 52 epochs de duración.	100
D.2. Desarrollo del entrenamiento con optimizador Adam y de 47 epochs de duración.	100
D.3. Desarrollo del entrenamiento con optimizador Adam y de 31 epochs de duración.	101
D.4. Desarrollo del entrenamiento con optimizador Adam y de 44 epochs de duración.	101
D.5. Escena nº 1 de resultados del conjunto de test del modelo entrenado con el BIAA.	102
D.6. Escena nº 2 de resultados del conjunto de test del modelo entrenado con el BIAA.	102
D.7. Escena nº 3 de resultados del conjunto de test del modelo entrenado con el BIAA.	103
D.8. Escena nº 4 de resultados del conjunto de test del modelo entrenado con el BIAA.	103
D.9. Escena nº 5 de resultados del conjunto de test del modelo entrenado con el BIAA.	104
D.10. Escena nº 6 de resultados del conjunto de test del modelo entrenado con el BIAA.	104

Lista de Tablas

3.1. Distribución de imágenes por municipio.	37
3.2. Parametrización de Segment Anything Model (SAM).	38
3.3. Etiquetas del BIAA y su relevancia para tareas de mantenimiento urbano.	41
4.1. Frecuencias de las variables binarias sobre el muestreo de 400 imágenes del conjunto de <i>ground truth</i>	50
4.2. Frecuencias de las variables multiclase sobre el muestreo de 400 imágenes del conjunto de <i>ground truth</i>	51
4.3. Comparación del número de imágenes que vieron mejorado o empeorado el tiempo (minutos) preciso de su anotación manual a su posprocesamiento, dejando de lado las imágenes donde el tiempo de ambas tareas fue el mismo, en relación a su estrato intercuartil.	52
4.4. Comparación del número de imágenes que vieron mejorado o empeorado el tiempo preciso (en minutos) de su anotación manual a su posprocesamiento, dejando de lado las imágenes donde el tiempo de ambas tareas fue el mismo en relación a su perspectiva.	53
4.5. Comparación de las métricas de los cuatro entrenamientos de la arquitectura DeepLabV3 preentrenada con Cityscapes.	53
4.6. Comparación de las métricas mIoU e IoU por clase de los cuatro entrenamientos de la arquitectura DeepLabV3 preentrenada con Cityscapes sobre el conjunto de test.	54

Capítulo 1

Introducción. Necesidades y enfoque

1. Propuesta de título

Banco de Imágenes de Anotaciones de Aceras (BIAA): Primeros pasos para disponer de recursos estructurados para la mejora de la monitorización y el mantenimiento del espacio público en Barcelona.

2. Palabras clave (keywords)

Aprendizaje automático, Deep Learning, Segmentación semántica, Segmentación por instancias, Redes neuronales, Visión computacional, Mantenimiento de la vía pública, Urbanismo, Entornos urbanos, Aceras, Pavimentos, Monitorización, Detección de anomalías, Anotaciones de imágenes, Procesamiento de imágenes, Smart Cities, Sostenibilidad urbana, Conjuntos de datos, Benchmarks.

3. Resumen de la propuesta

El proyecto presente se centra en la creación y explotación del llamado *Banco de Imágenes de Anotaciones de Aceras* (BIAA), un conjunto de imágenes recopilado y diseñado por el autor para el estudio y la mejora del espacio público urbano mediante técnicas de visión computacional. El proyecto recopila, organiza y anota un conjunto de imágenes de aceras en Barcelona y su área metropolitana, con el objetivo de facilitar el entrenamiento y la validación de modelos de aprendizaje automático orientados a la detección de anomalías en el pavimento.

La metodología combina la construcción de un *dataset* estructurado con anotaciones en formato estándar (COCO), la generación de máscaras de segmentación de instancias y el desarrollo de un *pipeline* reproducible para su utilización en tareas de clasificación y segmentación

semántica. Asimismo, se incorporan atributos relacionados con los metadatos como son la marca temporal, resolución de la imagen o sus coordenadas geográficas con el fin de enriquecer el análisis y garantizar su trazabilidad.

El proyecto persigue no solamente aportar un recurso valioso para la investigación en visión por computador aplicada al ámbito urbano, sino también abrir una línea de trabajo en la monitorización inteligente de infraestructuras públicas, con posibles aplicaciones futuras en sistemas de ciudades inteligentes y gestión predictiva del mantenimiento.

4. Descripción de la propuesta

La monitorización, auditoría y gestión del mantenimiento viario requiere, por una parte, identificar de forma fiable las superficies, que abarcan categorías desde la acera con piezas modulares o *panot* o bien pavimentada con asfaltado hasta la calzada asfáltica e incluyendo elementos como alcorques, el bordillo, la *rigola*, piezas de vados para vehículos o peatones y el mobiliario público. Por otro lado, también conlleva la detección de las incidencias como pueden ser piezas de pavimento levantadas o rotas, hundimientos, baches o elementos deteriorados por el tiempo, su uso o por actos vandálicos. Ante la insuficiencia apreciada de los medios de inspección actuales, nuestra propuesta es que la tarea de monitorización y auditoría podría automatizarse mediante el recurso de un modelo predictivo de segmentación por instancias.

Para ello, nuestra propuesta se centra en evaluar si los modelos de segmentación generalistas - por ejemplo, *Segment Anything* (SAM) preentrenado con el *dataset* SA-1B - resultan o no útiles para capturar bien la semántica viaria y si tanto su tendencia a la sobre-segmentación y al ruido como los errores por omisión o segmentación subóptima derivan también de una desalineación de dominio de sus datos de entrenamiento respecto al foco de interés de este proyecto, justificándose entonces la necesidad de disponer de un conjunto de datos específico para esta tarea - como sería el Banco de Imágenes de Anotaciones de Aceras (BIAA).

Para ello, este trabajo se centra en medir la eficiencia práctica de anotación y la robustez en escenarios reales a partir del conjunto de imágenes hasta ahora recopilado por el autor, además de comparar la preanotación con SAM frente a la anotación manual y evaluando el desempeño con métricas estándar y análisis cualitativo de errores.

4.1. Justificación

El mantenimiento de la vía pública, tanto del pavimento en la acera como en la calzada además de, generalmente, también el mobiliario como pueden ser los elementos de diversa índole del alumbrado público, bancos e incluso el arbolado, corresponde en España - y, generalmente, también en todos los países- a las corporaciones locales. Y, tal y como se observaría en la

última Encuesta de Servicios Municipales del Ayuntamiento de Barcelona, correspondiente al año 2024, entre las principales demandas ciudadanas respecto a la gestión del espacio público se encuentra el mantenimiento, siendo solamente superada por la limpieza y la inseguridad si descartamos las demandas referidas a problemáticas de naturaleza socioeconómica - como sería el acceso a la vivienda- o bien sobre servicios que presta el Ayuntamiento de Barcelona a la ciudadanía (Ajuntament de Barcelona [2024](#), p. 9).

Para atender esta demanda, es por este motivo que desde el año 2021 el Ayuntamiento de Barcelona ha puesto en práctica diversos planes o campañas específicas que se refieren también al mantenimiento de la vía pública, como serían *Cuidem Barcelona* (2021-2022) (Ajuntament de Barcelona [2021](#)) y, desde el año 2023, el *Pla Endreça Barcelona* (Ajuntament de Barcelona [2023](#)). Aunque no conocemos ejemplos de campañas de esta envergadura en otras capitales españolas, sí puede constatararse que en sus correspondientes corporaciones locales se realiza la contratación del servicio de mantenimiento de la vía pública de acuerdo a la periodicidad establecida por estas administraciones locales, aunque habitualmente la tarea específica de monitorización y auditoría se realiza por parte de la Administración local correspondiente. En cualquier caso, si bien se aprecia la dedicación de recursos para facilitar la comunicación de incidencias por parte de la ciudadanía como también la detección de oficio de incidencias por parte de las administraciones locales, habitualmente las actuaciones derivadas tienen carácter reactivo e inconsistentes además de requerir de un gran volumen de trabajo intensivo, dificultando poder planificar las actuaciones puntuales o actuar de forma proactiva.

Ampliando el foco más allá del contexto español, también conocemos iniciativas similares a la de Barcelona en Corea del Sur, en Japón y Estados Unidos relacionados con el progresivo envejecimiento de la población en ambos países, entendiéndose que son tanto el colectivo de la tercera edad como también de las personas con limitaciones para la movilidad las que, precisamente, son más vulnerables a las incidencias y desperfectos en la vía pública. Precisamente por este motivo, es en Corea del Sur (Choi, Ku y Lee [2022](#), p. 3570), Japón (T. Wang et al. [2025](#), p. 555) y Estados Unidos (Weld et al. [2019](#)), además de la misma España (Gemminis [2025](#)) donde se han impulsado, tanto a nivel académico como también empresarial, algunos proyectos de modelos predictivos que permitan clasificar y detectar desperfectos mediante imágenes bidimensionales.

4.2. Relevancia

El proyecto para la construcción del *Banco de Imágenes de Anotaciones de Aceras*, que actualmente incluye aproximadamente unas 3300 imágenes, entendemos que resulta de interés, en primer lugar, tanto para los gobiernos locales como también el sector privado de la construcción y el mantenimiento de infraestructuras ya que afecta directamente a sus competencias y activi-

dades. Por otra parte, aunque no siempre aparezca entre las principales prioridades declaradas por la ciudadanía, sí resulta una cuestión que afecta a amplios colectivos como son las personas ancianas o que viven con algún tipo de dificultad para la movilidad.

Por otro lado, este proyecto lo hallamos relevante también por el afán de integrar y poner el foco en las fases de recopilación, preprocesamiento, anotación y posprocesamiento de este nuevo conjunto de datos. Está justificado apreciar que frecuentemente en el campo de la Ciencia de datos se tiende a dedicar escasa atención a lo que frecuentemente se caracteriza como *data work*, siendo éste menos atractivo que el entrenamiento o el análisis de los resultados de los modelos de aprendizaje automático, aunque sea precisamente en estas fases que queremos tratar en este trabajo donde suelen hallarse las causas de la mayoría de fracasos en los proyectos de Ciencia de datos (Sambasivan et al. 2021). Esto resulta especialmente cierto en el caso de la anotación pues, como ha apuntado recientemente Anthony Sarkis, des de los equipos profesionales de Ciencia de datos frecuentemente se toman decisiones sobre el modelado sin haber atendido antes al problema de la anotación o supervisión de los datos (Sarkis 2024, págs. 105-106).

4.3. Objetivos

En el marco del presente proyecto de investigación nos planteamos estos objetivos:

- Recopilar un número suficiente de imágenes correspondientes a las aceras de la vía pública de Barcelona y otras poblaciones de su área metropolitana.
- Diseñar las definiciones que reflejen los requisitos del dominio, especialmente las referidas los criterios para considerar si una anomalía en el pavimento requiere de una actuación correctora no planificada, que posteriormente servirán para diseñar las etiquetas precisas para el proceso de anotación.
- Anotar dichas imágenes mediante máscaras de modo que resulten útiles para re-entrenar un modelo de segmentación por instancias.
- Diseñar una metodología que sirva para facilitar y reducir el número de horas de trabajo precisas para realizar esta tarea mediante el recurso de herramientas inteligentes que generen de forma automatizada máscaras etiquetadas sobre la imagen adaptadas al dominio.

5. Motivación personal

Este proyecto nace de la experiencia laboral del autor en el Ayuntamiento de Barcelona, donde trabajó entre 2021 y 2025 como administrativo. Entre sus tareas figuraba la detección

de incidencias en los pavimentos de aceras a partir de las imágenes remitidas por la ciudadanía a través de los distintos canales de comunicación municipales, evaluando tanto la actuación a realizar como serían sustituir las piezas de pavimento de una extensión determinada de superficie o recolocar una extensión determinada de metros lineales de piezas de bordillo. Una vez identificadas, debía redactar y tramitar la Orden de trabajo correspondiente para su reparación.

De esta experiencia profesional surgió también la conciencia del impacto social de dicha tarea: contribuir a mejorar las condiciones de vida de la ciudadanía. Esto resulta especialmente relevante en colectivos vulnerables como las personas mayores o aquellas con dificultades de movilidad. Entre estos últimos, destacan los casos de las personas invidentes y de los usuarios de sillas de ruedas, para quienes cualquier obstáculo en la accesibilidad supone un deterioro inmediato de su autonomía y calidad de vida.

Finalmente, este proyecto no solo representa una contribución al subcampo de la visión computacional, sino también una oportunidad para mejorar no solamente las tareas de monitorización y auditoría del mantenimiento de la vía pública si no también el proceso de valoración y activación de las medidas correctoras, abriendo la puerta a la optimización y automatización de los procedimientos actuales para, especialmente, agilizar y reducir el tiempo del ciclo de las actuaciones de mantenimiento correctivo no planificado.

6. Planificación y plan de investigación del proyecto

El desarrollo del proyecto se organiza en cuatro fases principales. En primer lugar, se completará la depuración del conjunto inicial de imágenes mediante procesos de preprocesamiento como el recorte y eliminación de imágenes borrosas. En segundo lugar, se procederá a la anotación manual de un subconjunto representativo de imágenes, apoyándose en herramientas como *LabelMe* y siguiendo criterios definidos previamente con la colaboración voluntaria de técnicos municipales mediante un cuestionario.

La tercera fase consistirá en la validación de estas anotaciones mediante la comparación con máscaras generadas por modelos de segmentación generalistas como SAM, DeeplabV3+, HR-Net o Mask2Former, evaluando su capacidad para generar segmentaciones semánticas ajustadas al dominio del BIAA, lo que permitirá evaluar la brecha de rendimiento entre modelos preentrenados y el dominio específico de las aceras de Barcelona. Para esta evaluación se emplearán métricas estándar como IoU y mIoU además del análisis cualitativo de los errores. La cuarta fase final consistirá en utilizar el modelo generalista de segmentación que ofrezca los mejores resultados desde el punto de vista cualitativo para poder realizar preanotación de las imágenes generando las máscaras para, posteriormente, evaluar la cantidad de tiempo de horas-trabajo requiere su posprocesamiento.

El plan de investigación combina, por tanto, un enfoque aplicado, como es la creación y validación de un recurso de datos, con una dimensión experimental como es la evaluación de modelos de segmentación sobre dicho recurso. Se prevé dedicar el primer mes a la fase de preprocesamiento y anotación inicial, un mes a la validación con SAM y métricas, y el último mes al posprocesamiento de una parte sustancial del *dataset* y la redacción de conclusiones.




Figura 1.1: Diagrama de cajas de la planificación del proyecto.

Como resultados esperados, se aspira a entregar un conjunto de datos anotados, documentado y coherente, acompañado de un análisis comparativo de modelos de segmentación que justifique la necesidad de *datasets* específicos para este ámbito. Asimismo, se propondrán posibles líneas de continuidad, incluyendo la ampliación de las anotaciones, el uso de arquitecturas más avanzadas y la exploración futura de metodologías 3D para la detección de incidencias en pavimentos de acera.

7. Compromiso ético y global (CEG) y Objetivos de Desarrollo Sostenible (ODS)

Este proyecto se alinea plenamente con los principios del compromiso ético y global, así como con los Objetivos de Desarrollo Sostenible (ODS), ya que su finalidad última es contribuir a mejorar de forma tangible las condiciones de vida de la ciudadanía y promover un entorno urbano más accesible, inclusivo y sostenible.

De manera particular, el proyecto pone el foco en garantizar el derecho a la movilidad de los colectivos más vulnerables, como las personas mayores o aquellas con dificultades en su movilidad personal. Entre estas últimas, destacan las personas con discapacidad visual o las que son usuarias de sillas de ruedas, para quienes cualquier irregularidad en el pavimento -baches, piezas rotas o desniveles- representa un obstáculo directo a su autonomía y calidad de vida.

La solución propuesta persigue optimizar los procesos de monitorización, auditoría y eva-

luación del mantenimiento urbano, permitiendo una detección más temprana y precisa de incidencias y optimizar también la valoración de las actuaciones correctoras oportunas. Con ello, se busca avanzar hacia una gestión más eficiente y proactiva del espacio público, alineada con los ODS 9 (Industria, innovación e infraestructura), 11 (Ciudades y comunidades sostenibles) y 10 (Reducción de las desigualdades).

8. Recapitulación y entregables

El *Banco de Imágenes de Anotaciones de Aceras* (BIAA) es un proyecto orientado a la creación de un recurso estructurado de imágenes anotadas del espacio público de Barcelona, destinado a mejorar la monitorización y el mantenimiento de las aceras mediante técnicas de visión por computador y aprendizaje profundo. A partir de un conjunto de más de 3.000 fotografías, el trabajo aborda las fases de preprocesamiento, anotación, validación y evaluación de modelos de segmentación —como SAM o Mask2Former— para analizar su capacidad de detectar incidencias en pavimentos urbanos. Más allá de su contribución técnica, el proyecto tiene una clara dimensión social y ética: promover la accesibilidad y la movilidad segura de los colectivos más vulnerables, como las personas mayores o con discapacidad, alineándose así con los Objetivos de Desarrollo Sostenible 9, 10 y 11, que abogan por infraestructuras resilientes, ciudades inclusivas y la reducción de las desigualdades.

Para ello, los entregables resultantes que nos proponemos serían:

- Un conjunto de datos de imágenes curadas y anotadas de acuerdo a los objetivos planteados y las definiciones coherentes a su dominio.
- Un subconjunto de datos que sirva como *ground truth* y, además, cuente con métricas que permitan evaluar y cuantificar la mejora que, potencialmente, los modelos de segmentación actualmente disponibles aportarían al proceso de anotación de estos datos.
- La memoria correspondiente.

Capítulo 2

Estado del arte

En este apartado se expone, en primer lugar, el problema del mantenimiento de las aceras, que es el espacio por el que en la inmensa mayoría de trayectos las personas acceden a otras modalidades de transporte tanto público o privado. Este medio ha de ser seguro y confortable, siendo la responsabilidad de su mantenimiento, en la mayor parte del mundo, de la Administración pública local. Para ello trataremos de describir los procedimientos y criterios para su mantenimiento desde la perspectiva de la ciudad de Barcelona aunque sin tampoco perder la perspectiva internacional, diferenciando además este problema del mantenimiento de otras estructuras como pueden ser las construcciones de hormigón o bien las calzadas. Y, por casi yuxtaposición, también trataremos brevemente del problema de la conducción automática.

En segundo lugar, también en este apartado se expone y justifica la aproximación metodológica adoptada en el presente proyecto de investigación, partiendo de los criterios propuestos por Anthony Sarkis (Sarkis 2024, pág. 95). En primer lugar, es necesario conocer los criterios con los que se ha construido un determinado conjunto de datos de entrenamiento; y, en segundo lugar, también entender que el proceso de anotación no puede concebirse de forma independiente al entrenamiento del modelo. De lo contrario, entendemos que un proyecto de datos alineado con los objetivos indicados en el capítulo anterior estaría destinado a su fracaso, especialmente por los fenómenos conocidos como *data drift* o *data cascade* y que, fundamentalmente, responden a la fragilidad del modelo entrenado para poder interactuar con el mundo real (Sambasivan et al. 2021, págs. 7-10).

Partiendo de este enfoque, nos proponemos evitar el usual esquema expositivo que, como Anthony Sarkis ha observado, "*tend to see training data as just one step to be bolted alongside a series of existing steps*" (Sarkis 2024, pág. 105). En cambio, sí proponemos hacer una exposición diacrónica en la que, en primer lugar, discutiremos sobre las diversas metodologías relevantes para atender al problema de la monitorización, auditoría y valoración del mantenimiento de aceras; y, en segundo lugar, plantear una discusión sobre los métodos de recopilación de datos

y la anotación de los mismos.

1. El problema del mantenimiento de las aceras

El mantenimiento de las aceras constituye una cuestión central en la gestión del espacio público urbano. Las aceras son, en la práctica, el principal soporte físico de la movilidad peatonal y el primer eslabón en la cadena de accesibilidad hacia cualquier otro modo de transporte, público o privado. Su conservación en condiciones adecuadas de seguridad, continuidad y confort determina no solo la calidad de la experiencia peatonal, sino también la inclusividad y sostenibilidad de la movilidad urbana en su conjunto.

Resulta relevante incidir en que la literatura académica sobre mantenimiento de aceras ha recibido históricamente una atención limitada en comparación con otras infraestructuras viarias, como las calzadas o los puentes (Sousa, Coutinho-Rodrigues y Natividade Jesus 2017; Bashiri, Raffini y Cepolina 2025), pese que el perfil del peatón fallecido en calzada o en acera es uno de lo más frecuentes en entornos urbanos (Mentis y Papadopoulos 2021). Ante esta escasa atención, el presente apartado aborda el problema del mantenimiento de las aceras en cuatro dimensiones complementarias. En primer lugar, presentaremos la figura del peatón como usuario fundamental del espacio público. A continuación, se examinan las competencias y procedimientos administrativos asociados a la gestión del mantenimiento de las aceras. Seguidamente, se establece una comparación con otros problemas de mantenimiento urbano, como el de las estructuras de hormigón - columnas y fachadas- o las calzadas. Finalmente, se presenta brevemente el problema de la conducción automática, cuyo desarrollo tecnológico en el campo de la visión computacional comparte múltiples elementos metodológicos con el problema aquí tratado.

1.1. El peatón

El peatón constituye el elemento más vulnerable y, al mismo tiempo, más constante de la movilidad urbana. A diferencia de otros modos de transporte, caminar no requiere infraestructura compleja ni energía externa, pero sí unas condiciones mínimas de seguridad, continuidad y confort que garanticen el ejercicio efectivo del derecho a la movilidad pues, en última instancia, es caminando por la acera como la mayoría de las personas acceden al resto de medios de transporte además de constituir el medio para los desplazamientos a menos de 1 km de distancia (Sousa, Coutinho-Rodrigues y Natividade Jesus 2017, págs. 1-2); dependiendo de su calidad también podrá aumentarse este rango en el marco de las políticas de la *ciudad caminable* impulsadas en numerosas ciudades - y, especialmente, en Barcelona- a raíz del confinamiento originado por la covid-19 (Valls y Clua 2023; Porfido et al. 2025).

Son también diversos los estudios que han puesto de relieve la relación directa entre la calidad del pavimento y la percepción de seguridad y bienestar de los peatones, especialmente entre personas mayores o con movilidad reducida (Corazza, Di Mascio y Moretti 2017; Fonseca, Rodrigues y Silva 2025; Porfido et al. 2025); en el caso de Roma, durante los años 2010-2012 se estableció la relación entre la práctica de los peatones, especialmente los mayores de 65 años, a caminar por la calzada - aumentando así también el número de accidentes de tráfico con peatones implicados- con el mal estado del pavimento de las aceras en la zona del barrio de Trieste, Distrito 2 de la capital italiana (Corazza, Di Mascio y Moretti 2017, págs. 196-198). En Atenas, un estudio valoró que para este grupo poblacional el mayor riesgo de lesiones era tanto por aceras que eran deslizantes en contextos de lluvia y también por presentar superficies aparentemente lisas pero que, en realidad, presentaban desniveles (Mentis y Papadopoulos 2021, pág. 4). Y estudios específicos realizados recientemente en tanto en Braga (Portugal) (Fonseca, Rodrigues y Silva 2025, pág. 13) como en Barcelona (Porfido et al. 2025) concluyeron que las personas de este grupo de edad valoraban como el mayor factor de riesgo las superficies irregulares o desniveladas. Aunque, como Bashiri, Raffini y Cepolina (2025) apuntan en su estudio sobre los criterios de mantenimiento de las aceras en Génova (Italia), al final cualquier mejora en los criterios de accesibilidad para las personas con movilidad reducida también favorece a muchos otros perfiles de peatones, como pueden ser las personas que acompañan a menores de edad o que deben acarrear equipajes o la compra cotidiana.

1.2. Competencias y procedimientos

El mantenimiento de las aceras forma parte de las competencias básicas de la administración local, al constituir un elemento esencial del dominio público destinado al uso común. En la mayoría de los ordenamientos de todo el mundo, su conservación y reparación recaen sobre los ayuntamientos o autoridades municipales, que deben garantizar su accesibilidad, seguridad y continuidad conforme a los principios de la movilidad urbana de sus respectivos marcos normativos¹.

Sin embargo, los procedimientos concretos mediante los cuales se ejerce esta competencia varían notablemente según el contexto institucional y la capacidad técnica de cada ciudad. En el caso de Barcelona, el mantenimiento de las aceras se gestiona a través de contratos plurianuales de conservación del espacio público impulsados por cada uno de los diez distritos administrativos del municipio. Estos contratos se articulan en torno a dos ejes: la inspección programada, que sigue un calendario de revisiones periódicas según tipología de vía, y la atención a incidencias,

¹En el caso de España, éste se define actualmente de acuerdo con la Orden Ministerial TMA/851/2021 (MiTM y AU 2021).

derivadas de avisos ciudadanos² o avisos compartidos por otros servicios municipales.

Este modelo combina, así, la planificación preventiva con la respuesta reactiva, si bien la primera continúa limitada por la disponibilidad de recursos pues cada año solo se logra inspeccionar una fracción reducida del total de aceras. Además, recae en la contrata correspondiente el criterio para seleccionar y documentar las incidencias detectadas, conduciendo al final a inconsistencias y diferencias de criterio entre diversos distritos; esta misma problemática se ha documentado en otros ejemplos muy alejados geográficamente como serían Corea del Sur (Choi, Ku y Lee 2022) o Japón (T. Wang et al. 2025). En este sentido, esta aproximación resulta útil para obtener inventarios parciales del estado de las aceras y del tipo de materiales, si bien soluciones tecnológicas como Gemminis³ están orientadas a garantizar más la exhaustividad de estos inventarios para, de este modo, fundamentar e informar las decisiones de donde realizar proyectos de reurbanización o mejora urbana a mediana y gran escala.

En cambio, este método de trabajo supone generar millares de fichas correspondientes a una imagen por ubicación y tipología de la incidencia detectada que, posteriormente, ha de ser revisada y valorada manualmente por un técnico municipal, siendo éste un procedimiento lento y tedioso que, a su vez, requiere también de conocimientos específicos si se quiere que esa imagen se traduzca, en la práctica, en una actuación de mantenimiento no planificado que la contrata de mantenimiento ejecute ajustándose a los requisitos especificados - identificando con precisión el problema a reparar, tipo de material a utilizar y especificando la superficie afectada - en un plazo razonable y optimizando los recursos públicos. En este sentido, debe subrayarse que no es un problema baladí el de detallar tanto tipología y superficie de la actuación, pues en el caso de piezas modulares se puede calcular la extensión en función del número de piezas.

Por otro lado, la comprensión de la logística material de estas actuaciones permite dimensionar mejor las limitaciones operativas que enfrentan los equipos municipales. El equipo de trabajo que realiza este tipo de actuaciones no planificadas son dos operarios en una furgoneta o camioneta que tiene una capacidad y volumen de carga limitado, pues un *panot de quatre pastilles* - el tipo de pieza más habitual en Barcelona - pesa aproximadamente 3 kg y dimensiones de 20 x 20 x 4 cm; 1 m² de superficie de acera con este material representan 25 piezas, es decir, unos 75 kg de peso. Teniendo en cuenta que también deben transportarse las herramientas de trabajo y cemento, un equipo de trabajo solamente puede esperar llevar material suficiente en su vehículo para 6 o 7 actuaciones pequeñas y, por lo tanto, es preciso saber con precisión qué modelo exacto de piezas deberán usarse en cada actuación que trate de ser integral y no meramente de fortuna.

En otros ámbitos geográficos se detectan tendencias diversas. En Estados Unidos, por ejem-

²Que pueden ser mediante instancia al mismo Ayuntamiento, comunicación a través de su página web o mediante el aplicativo de telefonía móvil *Barcelona a la Butxaca* (Ajuntament de Barcelona 2025).

³Que comentaremos con más detalle en apartados posteriores.

plo, en algunas grandes ciudades como Atlanta, Washington DC, Nueva York, Los Angeles, Boston, Seattle y Portland se aplica un modelo similar al de Barcelona aunque, mayoritariamente, la responsabilidad del mantenimiento de las aceras puede recaer parcialmente o totalmente en los propietarios de los inmuebles adyacentes, bajo esquemas de *shared responsibility* o mantenimiento compartido (Gibson y Marshall 2022, pág. 553). Este modelo busca reducir la carga financiera municipal, pero genera desigualdades territoriales significativas, ya que la calidad del espacio peatonal dependerá en gran medida de la renta del vecindario⁴. En este sentido, también debe observarse el contraste de esta aproximación desigual con el celo que estas mismas autoridades municipales sí realizan el mantenimiento de los pavimentos de las calzadas (Gibson y Marshall 2022, págs. 554-555) y de los vados peatonales fruto que, en ambos casos, sí existen marcos regulatorios estatales o federales⁵ que sí hacen explícitamente responsables a las corporaciones locales tanto de su inventariado como de su mantenimiento⁶.

A diferencia de las calzadas, cuyo mantenimiento se encuentra ampliamente estandarizado⁷ y priorizado en la mayoría de las ciudades, el de las aceras sigue siendo con frecuencia subsidiario y reactivo. En gran parte de los contextos urbanos, las estrategias de conservación continúan centradas en la circulación motorizada, reproduciendo un enfoque heredado de la ingeniería viaria tradicional, donde la movilidad peatonal se considera un aspecto accesorio (Gibson y Marshall 2022, págs. 559-561). También existen casos documentados en ciudades como Atenas o Roma (Mentis y Papadopoulos 2021; Corazza, Di Mascio y Moretti 2017) donde, aún existiendo marcos legales referentes a la obligación de estas administraciones locales para el mantenimiento de las aceras, resulta evidente que la falta de atención sostenida al mantenimiento de las aceras ha contribuido no solo a su degradación física, sino también al aumento del riesgo de accidentes, especialmente entre personas mayores o con movilidad reducida.

Frente a ello, se hace evidente la necesidad de avanzar hacia criterios de priorización comunes y homogéneos, capaces de integrar información visual y contextual sobre el estado real de las aceras. Solo de este modo puede aspirarse a un mantenimiento urbano que sea simultáneamente eficiente, equitativo y alineado con los principios de accesibilidad inclusiva.

⁴El mismo trabajo de Gibson y Marshall (2022) recoge el testimonio de un técnico municipal de Denver a finales del año 2020: "If a resident is struggling to afford groceries, how and why should we expect them to spend \$5000 fixing their sidewalk?" (Gibson y Marshall 2022, pág. 565).

⁵Como la llamada ADA o *American with Disabilities Act* (U.S. Department of Justice 2025).

⁶Es oportuno notar que, en algunos casos, las políticas municipales en determinadas ciudades tienden también a preferir realizar grandes proyectos de reforma urbana y marginar los relativamente más reducidos proyectos que se limitarían al mantenimiento, tal y como se ha observado en el estudio de P.J. Gibson y W.E. Marshall en Estados Unidos (Gibson y Marshall 2022, pág. 558).

⁷Existe una amplia literatura en referencia a los modelos *Pavement Magement Systems* y que, a veces, se ha querido trasladar sus metodologías de evaluación para el caso de las aceras (Sousa, Coutinho-Rodrigues y Natividade Jesus 2017; Bashiri, Raffini y Cepolina 2025).

1.3. Qué es una incidencia: del pavimento de las aceras a otras infraestructuras urbanas

Antes de definir qué constituye una anomalía, conviene precisar el objeto mismo de análisis. Una acera⁸ puede definirse como un ámbito habitualmente público destinado al paso exclusivo de peatones, diferenciado del resto de la calzada por sus materiales, rasante, colorimetría y elementos urbanos asociados. Incluye, además, todos los componentes necesarios para el correcto funcionamiento del espacio público municipal: pavimento, bordillos, alcorques, tapas de servicios, rampas, bancos o señalización. En consecuencia, su mantenimiento no se limita a la integridad del pavimento, sino que abarca la totalidad de los elementos que configuran su funcionalidad y accesibilidad.

Bajo esta definición, una incidencia en una acera puede entenderse como cualquier elemento que se encuentra en mal estado o que representa un riesgo para el correcto desarrollo de la vida cotidiana, ya sea del propio pavimento o de cualquiera de los elementos urbanos integrados en él. En términos técnicos, una incidencia o anomalía describe cualquier alteración geométrica, superficial o funcional que interrumpe la regularidad y seguridad del tránsito peatonal. Estas alteraciones pueden manifestarse en forma de losetas desplazadas, fisuras, baches, hundimientos, levantamientos por raíces, pérdida de material o la presencia de objetos que obstaculizan el paso. A diferencia de los defectos estructurales en edificaciones o calzadas, las anomalías en las aceras afectan de manera directa la experiencia del peatón, por lo que su gravedad debe evaluarse no solo por su dimensión física, sino también por su impacto en la movilidad y la seguridad.

El carácter híbrido de la acera - entre la infraestructura y el espacio de relación humana - explica parte de la complejidad del mantenimiento urbano. Una irregularidad de apenas dos centímetros puede no comprometer la estabilidad del material, pero sí generar tropiezos o caídas, especialmente entre personas mayores o con movilidad reducida⁹. Así, el concepto de anomalía en este contexto no remite únicamente a un defecto material, sino a una discontinuidad funcional, es decir, a cualquier condición que limite el uso seguro y accesible del espacio peatonal.

En comparación, las anomalías o desperfectos en otras infraestructuras urbanas, como las estructuras de hormigón o las calzadas, se caracterizan por enfoques metodológicos mucho más consolidados. En el ámbito de las estructuras verticales —fachadas, muros o pilares—, las anomalías se identifican principalmente como patologías físicas del material: fisuras, corrosión de armaduras, eflorescencias o desprendimientos. Su detección y valoración, epistemológicamente, es frecuentemente indicativa de un deterioro del conjunto de la estructura y se realizan median-

⁸Las definiciones que detallamos a continuación han sido suministradas por Rubèn Valldeoriola Domínguez, técnico en un distrito del Ayuntamiento de Barcelona. Véase la respuesta a la Pregunta 5 en Cuestionario (Anexo A).

⁹Como se observa en la microencuesta realizada recientemente en Braga (Portugal) por Fonseca, Rodrigues y Silva (2025).




Figura 2.1: Ejemplos de desperfectos en estructuras de hormigón, máscaras *ground truth* manuales y la predicción de las máscaras visualizadas por el *logit* de cada píxel, en este caso, por un modelo de arquitectura U-Net (Ahmadi et al. 2025).

te inspección visual o técnicas no destructivas, siguiendo protocolos estandarizados orientados a garantizar la seguridad estructural (Utami, Osorio Sandoval y Thom 2024), existiendo también metodologías de visión computacional con modelos de segmentación semántica que han demostrado ser útiles para su detección (Ahmadi et al. 2025).

En el caso de las calzadas, el mantenimiento se apoya en sistemas avanzados de *Pavement Management Systems* (PMS), que permiten clasificar y cuantificar defectos de superficie —grietas, baches, deformaciones, pérdida de textura— con criterios de severidad y extensión, generando indicadores objetivos como el *Pavement Condition Index* (PCI) o el *Surface Distress Index* (Sousa, Coutinho-Rodrigues y Natividade Jesus 2017; Utami, Osorio Sandoval y Thom 2024; Bashiri, Raffini y Cepolina 2025). Estos modelos posibilitan una planificación predictiva del deterioro y una priorización basada en eficiencia económica y riesgo funcional.

En contraste, las aceras carecen de un marco metodológico equivalente. La falta de métricas estandarizadas y la diversidad de materiales y condiciones urbanas dificultan la aplicación de criterios uniformes de diagnóstico. Además, la evaluación de incidencias depende aún del juicio

subjetivo del técnico o del contratista¹⁰, lo que produce variabilidad en la identificación y clasificación de los defectos. Esta ausencia de sistematización no solo limita la comparación entre territorios, sino que dificulta también la implementación de políticas de mantenimiento preventivo y equitativo.



Figura 2.2: Ejemplo de la diferencia de los desperfectos observables en pavimentos modulares y asfálticos. *Izquierda:* se observa una tapa de registro hundida - posiblemente por la circulación por la acera de un vehículo de gran tonelaje- y que también ha ocasionado desperfectos - por resquebrajamiento o desplazamiento- en los *panots* adyacentes. El área afectada puede calcularse en base al número de piezas que pueden apreciarse como rotas o desplazadas. *Derecha:* se observa una tapa de alcantarillado público en calzada que muestra también hundida debido a la circulación de autobuses y otros vehículos de gran tonelaje por la vía; se observa que el asfaltado se ha grietado por la deformación del mismo causado por el hundimiento de la tapa de alcantarillado, hasta al punto de haberse producido la pérdida de parte del material. El área afectada sólo puede estimarse si se conoce la escala de cada píxel de la imagen en el mundo real. Fuente propia.

Dentro del caso de los diversos tipos de pavimento de acera, existen dos grandes tipologías: los pavimentos asfálticos - más similares a los de la calzada- y los pavimentos con piezas modulares de hormigón u otros materiales. Recientemente, desde el campo de la visión computacional (T. Wang et al. 2025) se ha constatado que el problema analítico resulta fundamentalmente distinto ya que las grietas o la deformación de los materiales presenta rasgos característicos distintos: en el caso del pavimento asfáltico, el dominio se representará con una función continua de valores - superficie- mientras que, en el caso del pavimento modular, el dominio se puede representar como un conjunto finito de valores - piezas- y, por lo tanto, resulta imperativo tratarlos como problemas analíticos también distintos (ver Figura 2.2).

Por todo ello, resulta necesario avanzar hacia una definición operativa y automatizable de lo que constituye una anomalía o incidencia en la acera, integrando tanto la dimensión material

¹⁰En este último caso, el criterio de los operarios que realizan esta tarea tiende a ser menos consistente al carecer de la formación específica precisa; como observa el estudio P.J. Gibson y W.E. Marshall de 16 ciudades estadounidenses, la valoración de una anomalía o deficiencia en una acera puede resultar más compleja que no las ubicadas en calzada (Gibson y Marshall 2022, pág. 558).

como la funcional. Solo mediante la estandarización de estos criterios —basados en datos visuales, espaciales y contextuales— podrá alcanzarse un modelo de mantenimiento urbano que combine precisión técnica, coherencia territorial y sensibilidad hacia la experiencia del peatón. Este enfoque, en última instancia, enlaza con los desarrollos recientes en visión computacional orientados a la detección automática de defectos, que se abordarán en los capítulos siguientes.

1.4. Un problema yuxtapuesto: la conducción automática

El desarrollo de la conducción automática comparte numerosos retos analíticos con el problema del mantenimiento de las aceras, especialmente en lo relativo a la detección y segmentación de superficies, materiales y obstáculos en entornos urbanos. En este campo, la visión computacional ha alcanzado un grado notable de sofisticación, impulsado por la necesidad de interpretar escenas viales en tiempo real y bajo condiciones cambiantes de iluminación, climatología o densidad de tráfico.

Sin embargo, como señalan Almazroey, Jarraya y Alnanih (2025), incluso los modelos más avanzados —incluido el *Segment Anything Model* (SAM)— continúan enfrentando importantes limitaciones cuando se aplican al dominio viario. La variabilidad de texturas y colores, la presencia de reflejos o sombras y la necesidad de distinguir entre objetos móviles y estáticos dificultan la segmentación precisa de los elementos de la calzada. Estos desafíos son aún más acusados en entornos peatonales, donde la morfología de los pavimentos, su estado de conservación y la heterogeneidad de materiales introducen una complejidad adicional.

Una diferencia crítica entre ambos problemas radica en el factor temporal del procesamiento. En la conducción automática, el tiempo de inferencia —incluso cuando se dispone de unidades de procesamiento gráfico (GPU)— constituye un parámetro de seguridad: las decisiones del modelo deben producirse en milisegundos para evitar colisiones o maniobras peligrosas y, a su vez, sin requerir equipar al vehículo con sistemas tecnológicos que dispararían el coste (Almazroey, Jarraya y Alnanih 2025, págs. 19-20). En cambio, en el mantenimiento de las aceras, el análisis puede realizarse de manera asíncrona y sin requerimientos de inmediatez, lo que permite utilizar modelos más complejos o de mayor resolución, optimizando la precisión por encima de la velocidad. Esta flexibilidad computacional amplía el abanico de técnicas posibles, facilitando la adopción de arquitecturas de segmentación de alta calidad que en el contexto automotriz serían impracticables.

En consecuencia, los avances logrados en la conducción automática resultan inspiradores pero no directamente transferibles. Más bien, evidencian la necesidad de adaptar los marcos de segmentación existentes a los requerimientos específicos del espacio peatonal, donde la escala, la textura y la función de los elementos urbanos difieren sustancialmente de los de la calzada. Este es, precisamente, el enfoque que guía el presente proyecto, orientado a desarrollar un modelo

de análisis visual que responda a la realidad material y funcional de las aceras.

2. El problema de la visión computacional

La visión computacional tiene por objetivo, mediante el uso de redes neuronales convolucionales, emular los procesos de percepción visual observados en los animales y, en última instancia, en los propios seres humanos (Géron 2023, pág. 479). Dentro de este subcampo del *deep learning* se distinguen cuatro metodologías especialmente relevantes para nuestro problema analítico: la clasificación de escenas, la detección de objetos, la segmentación semántica y la segmentación por instancias (Géron 2023, págs. 521-534)¹¹.

En esta línea, en este apartado trataremos en primer lugar del paradigma COCO para, luego, presentar en detalle las cuatro metodologías indicadas.

2.1. El paradigma COCO

El lanzamiento del conjunto de datos *Common Objects in Context* (COCO) por parte de Lin et al. (2015) con el impulso de Microsoft, supuso un punto de inflexión en la evolución de la visión computacional. Este conjunto de datos no solamente amplió de forma significativa el volumen y la diversidad de imágenes disponibles, sino que redefinió las relaciones entre las principales metodologías del subcampo de la visión computacional. Frente a los conjuntos de datos anteriores —como ImageNet—, en los que las imágenes se presentaban mayoritariamente de forma aislada, COCO introdujo una noción de contexto: los objetos aparecen en escenas complejas, parcialmente ocluidos, con escalas variables y en condiciones lumínicas diversas. Esta orientación hacia contextos realistas permitió desarrollar modelos más robustos y generalizables, capaces de interpretar escenas urbanas de manera más próxima a la percepción humana.

El paradigma COCO también estableció un lenguaje común para el entrenamiento y la evaluación de los modelos de visión computacional, al proponer un formato estandarizado de anotaciones (en JSON) que describe con precisión la posición, forma y clase de cada objeto según coordenadas poligonales o cajas delimitadoras. Dicho formato se ha convertido en un referente transversal adoptado por la mayoría de las arquitecturas actuales, desde Faster R-CNN y Mask

¹¹Escogemos deliberadamente la clasificación de metodologías que plantea Aurélien Géron en su trabajo ya citado, además de Neuhold et al. (2017) y Sun et al. (2019), al entender que, en nuestro caso concreto, permite delimitar mejor los diversos casos de uso que admiten cada una de estas metodologías. Por ello, también excluimos de este trabajo la estimación de posturas o *pose estimation* que versa sobre la detección de objetos mediante *keypoints* en vez de cajas o *bounding boxes* y que se emplea para la detección de figuras humanas como indica A. Sarkis (Sarkis 2024, pág. 92), no siendo esta tarea objeto de interés en este estudio. Asimismo, descartamos amalgamar la segmentación semántica con la segmentación por instancias, tal y como plantea A. Sarkis (Sarkis 2024, págs. 90-91) o la amalgama de las metodologías de clasificación y detección de objetos que plantea Cordts et al. (2016).

R-CNN hasta DeepLab o Segment Anything, facilitando también la interoperabilidad de los modelos y la comparación objetiva de resultados mediante métricas compartidas como la *mean Average Precision* (mAP), que evalúa el promedio de la relación entre precisión y sensibilidad (Géron 2023, pág. 529); o la *Intersection over Union* (IoU), que mide el grado de coincidencia entre las máscaras de predicción y las máscaras de referencia - las llamadas *ground truth*-elaboradas por un anotador humano (Kirillov et al. 2023, pág. 4022)¹².

En este sentido, COCO no debe entenderse únicamente como un repositorio de imágenes útil como *benchmark* (Sarkis 2024, pág. 197), sino como un auténtico paradigma metodológico que integra datos, modelos y métricas en un mismo ecosistema. Este enfoque permitió que la visión computacional superase el marco estrictamente académico para abordar también problemas complejos de carácter urbano como la monitorización de infraestructuras, el análisis del tráfico o la detección de anomalías en el espacio público, como es nuestro caso.

2.2. La clasificación de escenas

La clasificación de escenas constituye el punto de partida histórico de la visión computacional moderna, ya que fue la primera tarea en la que los modelos de *deep learning* demostraron una capacidad de generalización comparable o incluso superior a la percepción humana. Esta metodología tiene por objetivo asignar una etiqueta global a una imagen completa (Sarkis 2024, pág. 92), sin distinguir entre los distintos objetos que la componen ni identificar de manera explícita los elementos individuales presentes en ella.

Los avances logrados a partir de redes neuronales convolucionales - especialmente desde la introducción de AlexNet en 2012 y su posterior evolución hacia arquitecturas más profundas como VGG o ResNet- permitieron que la clasificación de escenas se consolidara como una tarea fundamental para el reconocimiento visual automático (Géron 2023, págs. 521-522). En este contexto, conjuntos de datos como ImageNet ofrecieron millones de imágenes etiquetadas que sirvieron para entrenar modelos con una notable capacidad de abstracción, capaces de reconocer patrones visuales complejos asociados a entornos específicos¹³.

Sin embargo, esta metodología presenta limitaciones evidentes para el análisis de entornos urbanos. Al proporcionar una única etiqueta por imagen, la clasificación de escenas no distingue entre diferentes regiones o elementos del espacio público, lo que impide evaluar con precisión aspectos concretos como el estado del pavimento o la presencia de obstáculos en la acera. En otras palabras, los modelos de clasificación ofrecen la apariencia de una solución directa al problema analítico de la monitorización, auditoría y evaluación del estado de mantenimiento de

¹²Aunque también se ha advertido que esta métrica está sesgada al favorecer los objetos más grandes (Cordts et al. 2016, pág. 3217).

¹³Aunque, como se verá en el siguiente apartado 2 (*infra*), padeciendo de sesgos fruto de su concepción.

las aceras aunque, a nuestro juicio, resultan insuficientes para diagnosticar fenómenos locales (Sarkis 2024, pág. 83)¹⁴ además de presentar el problema de los *background fools* (Xiao et al. 2020) o las correlaciones espurias.

A pesar de sus limitaciones, la clasificación de escenas conserva un interés instrumental en el marco de la visión computacional, especialmente como etapa preliminar que proporciona información contextual para tareas más precisas, como la detección y la segmentación. Desde este punto de vista, su evolución marca el paso de un enfoque global de la imagen a otro orientado a la identificación de objetos concretos, lo que analizaremos en el siguiente apartado.

2.3. La detección de objetos

La detección de objetos representa un avance decisivo respecto a la clasificación de escenas, al permitir identificar de manera explícita las entidades presentes en una imagen junto con su localización (Géron 2023, págs. 522-524). Mientras que la clasificación asigna una única etiqueta global a la totalidad del contenido visual, la detección establece un vínculo entre las etiquetas y las regiones específicas donde los objetos aparecen (Sarkis 2024, pág. 92). Este cambio metodológico permitió un salto cualitativo en la capacidad de los modelos para analizar escenas complejas, particularmente en entornos urbanos donde coexisten múltiples elementos relevantes, tales como peatones, vehículos, señales o pavimentos¹⁵.

Los primeros avances en detección de objetos basados en redes neuronales convolucionales se dio con la familia de modelos R-CNN o *Regions with convolutional neural networks*, consolidándose con la posterior aparición de arquitecturas de detección unificada, como YOLO (*You Only Look Once*), permitiendo acelerar los tiempos de inferencia y abrió la puerta a aplicaciones en tiempo real, aspecto clave en los sistemas de monitorización urbana (Géron 2023, págs. 527-528)¹⁶.

La detección de objetos, sin embargo, no se limita a identificar la presencia o ausencia de un elemento, sino que también implica determinar con precisión su posición en el espacio de la imagen mediante cajas delimitadoras o *bounding boxes*. Este tipo de representación ha demostrado ser especialmente útil para la vigilancia del tráfico, el conteo de peatones y la

¹⁴Estimamos que éste es el caso de numerosos estudios publicados sobre esta cuestión, como Laohaprapanon, Ortleb y Sood (2018), Yoon, Kim y Jeong (2022), Choi, Ku y Lee (2022), De Deijn y Bukralia (2024), Weld et al. (2019) y Li et al. (2024). En algunos casos este método de clasificación ha ido acompañado del uso de características adicionales obtenidas mediante Lidar (Yoon, Kim y Jeong 2022) o bien recurriendo a añadir referencias posicionales en el mapa de píxels de la imagen y geocoordenadas (Weld et al. 2019; Li et al. 2024) con resultados dispares, como ya discutiremos en el siguiente capítulo de este trabajo.

¹⁵Un ejemplo aplicado de esta metodología es el sistema desarrollado por la empresa Gemminis para la detección de incidencias en el pavimento de aceras (Gemminis 2025).

¹⁶Aunque en el caso del mantenimiento de las aceras, que son objetos esencialmente inertes y en contraste con objetos en movimiento como son los vehículos en un flujo de tráfico, quizás no sea relevante. Abundaremos más sobre esta cuestión en el próximo capítulo.

identificación de elementos del mobiliario urbano, aunque presenta limitaciones para tareas que requieren distinguir formas irregulares o contornos difusos, como es el caso de las grietas o discontinuidades en el pavimento debido a que esta metodología identifica los objetos mediante regiones rectangulares, una abstracción que rara vez coincide con la morfología real de los elementos del entorno como ha advertido A. Sarkis (Sarkis 2024, pág. 162). En tales situaciones, la información aportada por las *bounding boxes* resulta insuficiente, ya que no permite estimar con precisión la extensión ni la morfología del objeto detectado.

Desde el punto de vista metodológico, la detección de objetos introdujo un enfoque más granular que el de la clasificación de escenas, sentando las bases de la segmentación por instancias. En efecto, la capacidad de localizar regiones de interés dentro de la imagen permitió redefinir el modo en que los modelos de visión computacional hacen el *mapping* de una escena, pasando de la simple asociación de etiquetas globales a la interpretación estructurada de sus componentes.

2.4. La segmentación semántica

La segmentación semántica constituye un paso crucial en la evolución de la visión computacional, al permitir asignar una etiqueta de clase a cada píxel de una imagen (Sarkis 2024, págs. 90-91). A diferencia de la detección de objetos, que delimita regiones mediante *bounding boxes*, la segmentación semántica proporciona una descripción más precisa de las fronteras y la morfología de los objetos (He et al. 2020), aunque sin diferenciar entre objetos de una misma clase (Géron 2023, pág. 531).

El desarrollo de la segmentación semántica moderna se consolidó con las redes completamente convolucionales o *Fully convolutional networks* (Géron 2023, págs. 525-526), que sustituyeron las capas densas tradicionales por convoluciones de salida espacial por mapas de etiquetas con la misma resolución espacial que la imagen original. Posteriormente, arquitecturas más avanzadas como DeepLab (L.-C. Chen et al. 2018) introdujeron técnicas de *atrous convolution* para ampliar el campo receptivo sin pérdida de resolución, mientras que HRNet (Sun et al. 2019) logró mantener representaciones de alta resolución a lo largo de todo el proceso de inferencia.

Más recientemente, el modelo Mask2Former (Cheng et al. 2022) ha generalizado este enfoque mediante una arquitectura basada en *masked attention transformers*, capaz de unificar las tareas de segmentación semántica, por instancias y panóptica bajo un mismo marco de aprendizaje. Esta integración representa un paso decisivo hacia una comprensión más flexible y contextual de las escenas, al permitir que el modelo aprenda representaciones compartidas y adaptables a distintos niveles de granularidad. En conjunto, estos avances han marcado un punto de inflexión al combinar precisión geométrica y coherencia contextual, dos aspectos fundamentales para la interpretación de escenas urbanas complejas.



Figura 2.3: Ejemplo de segmentación semántica con una red neuronal profunda entrenada con el *dataset* Cityscapes añadiendo algunas instancias adicionales para lograr su adaptación al dominio (Y.-H. Chen et al. 2017).

En el ámbito de la monitorización urbana, la segmentación semántica ha demostrado ser una herramienta eficaz para la detección y clasificación de materiales de superficie (Hosseini, Miranda et al. 2022), la identificación de aceras y calzadas (Hosseini, Sevtsuk et al. 2023; Shihab, Bhagat y Sharma 2024) o la evaluación del estado del pavimento (Y.-H. Chen et al. 2017). Su principal fortaleza radica en la capacidad para transformar una imagen convencional en un mapa de clases que refleja de forma explícita los componentes estructurales del espacio público, siendo una herramienta especialmente útil para tareas de inventariado¹⁷.

No obstante, esta metodología también presenta limitaciones relevantes. Como ya hemos indicado, al asignar una única etiqueta por píxel, no distingue entre distintas instancias de una misma clase como pueden ser dos piezas modulares de pavimentos, lo que imposibilita tanto el análisis individualizado de las unidades físicas o poder realizar transformaciones sencillas como, por ejemplo, calcular el área a partir del número de piezas del mismo tipo de pavimento modular. Por otro lado, la precisión de las máscaras generadas depende en gran medida de la calidad del proceso de anotación¹⁸. Finalmente, el entrenamiento de modelos de segmentación semántica suele requerir un volumen elevado de datos etiquetados, lo que incrementa los costes de desarrollo y pone de relieve la necesidad de estrategias eficientes de anotación y *transfer learning*, además de depender de la misma variabilidad del conjunto de datos de entrenamiento

¹⁷Siendo, precisamente, otro de los casos de uso observado en el caso de Gemminis (2025).

¹⁸Esta cuestión se tratará con más profundidad en el siguiente apartado 2.3.2.

para obtener modelos robustos capaces de lidiar ante cambios de la distribución en nuevos datos - *epistemic and aleatoric uncertainty*- como también ante objetos desconocidos, ya sea por estar no presentes en el mismo conjunto de datos de entrenamiento - *epistemic uncertainty*- (Franchi et al. 2021) o bien porque no se logra la generalización al estar entrenado el modelo con datos de dominios muy específicos que dan lugar al fenómeno del *domain gap* (Zou et al. 2019, págs. 297-298).

En conjunto, la segmentación semántica representa una aproximación intermedia entre la detección de objetos y la segmentación por instancias. En este sentido, constituye el punto de partida natural hacia metodologías más avanzadas orientadas a la identificación y caracterización diferenciada de cada objeto, como veremos en el siguiente apartado.

2.5. La segmentación por instancias

La segmentación por instancias representa la evolución natural de la segmentación semántica al introducir la capacidad de distinguir entre objetos individuales de una misma clase, asignando a cada uno una máscara y una etiqueta únicas (Sarkis 2024, pág. 90). En otras palabras, esta metodología combina la precisión geométrica de la segmentación semántica con la capacidad de conteo y diferenciación propia de la detección de objetos, situándose como una de las aproximaciones más completas en la visión computacional contemporánea.

El desarrollo de esta técnica se consolidó con la introducción de Mask R-CNN (He et al. 2020), que extendió el marco de Faster R-CNN añadiendo una rama paralela dedicada a la predicción de máscaras por cada *bounding box* detectada. Este avance permitió, por primera vez, aislar y segmentar objetos individuales con gran precisión espacial, convirtiéndose en la arquitectura de referencia durante más de un lustro.

La aparición de modelos más recientes como Mask2Former (Cheng et al. 2022) y SAM (Kirillov et al. 2023; Ravi et al. 2024) ha supuesto una transformación significativa en la forma de abordar la segmentación por instancias. Mask2Former unificó en un único marco las tareas semántica, panóptica e instanciada, gracias al uso de *masked attention transformers* que permiten manejar un número variable de objetos y escalas. Por su parte, *Segment Anything Model* (SAM) propuso un enfoque *prompt-based*, en el que las máscaras se generan también a partir de instrucciones o puntos de referencia proporcionados por el usuario, abriendo la puerta a esquemas interactivos de anotación semiautomática¹⁹. Cabe destacar, además, la extensa literatura dedicada a las aplicaciones de SAM para su uso en el campo de la medicina (Fan et al. 2025), el mantenimiento de infraestructura civil (Ahmadi et al. 2025) como también otras actividades como el control de calidad en la industria, la detección de rasgos geográficos o la agricultura

¹⁹Véase una propuesta de automatización de la generación de los *prompts* en Y. Chen et al. (2025).




Figura 2.4: Ejemplo de segmentación por instancias con SAM con muestras de los 23 *benchmarks* utilizados en la publicación original de Kirillov et al. (2023).

(X. Wang et al. 2025).

En el contexto urbano, la segmentación por instancias ofrece ventajas decisivas para la monitorización del espacio público, al permitir identificar y cuantificar elementos específicos del entorno - por ejemplo, un banco, una pieza de bordillo o un alcorque concretos- de manera individualizada²⁰. Esta granularidad facilita tanto la estimación de superficies o unidades afectadas como la priorización de intervenciones de mantenimiento, obteniéndose un *output* que puede transformarse con facilidad en una actuación para su reparación o sustitución. Además, constituye una base idónea para la construcción de conjuntos de datos estructurados al facilitar la tarea de preanotación al automatizarla, como el propuesto en este proyecto, que requieren diferenciar unidades físicas discretas dentro de una misma clase de objeto. Finalmente, ejemplos como GeoSAM (Ibn Sultan et al. 2024) nos sugieren que es una herramienta adaptable a dominios específicos.

No obstante, esta metodología plantea también desafíos técnicos significativos. El entrenamiento de modelos de segmentación por instancias exige anotaciones mucho más detalladas y costosas que las de segmentación semántica (Sarkis 2024, pág. 82), lo que incrementa la dependencia de técnicas de *transfer learning* o de métodos de segmentación automática asistida. Asimismo, persisten problemas de sobreajuste espacial en conjuntos de datos urbanos limitados, donde las variaciones de perspectiva o iluminación pueden comprometer la generalización del modelo²¹.

Otro problema relevante hace referencia al fenómeno de la sobresegmentación, al generar máscaras repetidas o redundantes de los mismos objetos en la imagen y que, por lo tanto, quizás requiriesen un trabajo de posprocesamiento manual de las máscaras predecidas por SAM, además de aumentar notablemente el coste computacional. Siendo ambos factores a

²⁰Resulta de interés recoger los resultados de la reciente investigación de Almazroey, Jarraya y Alnanih (2025) para el caso de segmentación de objetos en contextos de calzada.

²¹Esta cuestión la trataremos con más detenimiento en el siguiente subapartado 2.3.1.

tener en cuenta, también debe apuntarse que se han sugerido estrategias para reducir esta sobresegmentación, ya sea mediante el uso de *prompts* fruto de un mapeo de las características de la imagen (Y. Chen et al. 2025) o bien del filtrado de aquellas máscaras con puntuaciones de IoU por debajo de un umbral determinado (Almazroey, Jarraya y Alnanih 2025).

En síntesis, la segmentación por instancias constituye el punto de convergencia entre la semántica y la geométrica en la visión computacional. Su capacidad para distinguir objetos individuales y preservar sus límites reales la convierte en la metodología más prometedora para abordar tareas de inventariado, diagnóstico y evaluación de actuaciones en entornos urbanos de forma asistida, así como el pilar conceptual sobre el que se fundamenta el desarrollo del presente proyecto.

3. El problema de la creación del conjunto de datos

Como se ha señalado en el apartado anterior, la evolución de las metodologías de visión computacional ha estado estrechamente ligada a la disponibilidad de conjuntos de datos amplios, diversos y adecuadamente anotados. Sin embargo, la creación de dichos conjuntos no constituye un proceso neutral ni meramente técnico: es, ante todo, una tarea epistemológica y operativa que condiciona la validez, la generalización y la robustez de los modelos entrenados (Denton et al. 2021; Paullada et al. 2021); como observa A. Sarkis, el 99 % de las horas de trabajo de un equipo completo tendrán relación a la recopilación y anotación de los datos, correspondiendo al 1 % restante las tareas de modelado en sí (Sarkis 2024, pág. 22).

El conjunto de datos es el punto de partida -y a menudo también el límite- de cualquier proyecto de aprendizaje automático. De su composición, calidad y representatividad depende en gran medida la capacidad del modelo para desenvolverse en contextos reales, donde las distribuciones de los datos no tienen porqué con las del entrenamiento y, por lo tanto, son estos los que deben parecerse lo más posible al que se empleará en su caso de uso (Sarkis 2024, págs. 23-24). En este sentido, autores como (Sambasivan et al. 2021) han advertido sobre los riesgos de los denominados *data cascades*, que se producen cuando los errores o sesgos introducidos en fases tempranas del ciclo de datos se propagan a lo largo del proceso de modelización, afectando a la fiabilidad de los resultados y, en última instancia, a su impacto social.

Desde esta perspectiva, el presente capítulo se centra en analizar los principales desafíos asociados a la creación y estructuración de conjuntos de datos urbanos destinados a tareas de segmentación y monitorización del espacio público. En particular, se abordarán dos dimensiones esenciales y complementarias del problema:

1. la recopilación de datos, tanto mediante fuentes masivas como Google Street View o las fotografías aéreas o imágenes satelitales, como mediante campañas específicas de toma de



Figura 2.5: Ejemplo ilustrativo de *data drift*, tal y como pone de relieve Anthony Sarkis (Sarkis 2024, pág. 23).

imágenes a pie de calle; y

2. la anotación de los datos, entendida no solo como un proceso técnico de etiquetado, sino como una práctica situada que refleja decisiones conceptuales, metodológicas y éticas sobre qué se considera relevante observar y representar.

El objetivo, en definitiva, es situar la creación del conjunto de datos no como un paso previo a la modelización, sino como una parte constitutiva del propio proceso de aprendizaje.

3.1. De las fuentes masivas de datos a la recopilación de datos sobre el terreno

La mayor parte de los avances recientes en visión computacional aplicada al entorno urbano han dependido de grandes repositorios de imágenes anotadas, concebidos como bancos de referencia o *benchmarks* para el desarrollo y evaluación de modelos. Entre ellos destacan Cityscapes (Cordts et al. 2016), Mapillary Vistas (Neuhold et al. 2017) y BDD100K (Yu et al. 2020), que han establecido los estándares metodológicos y técnicos en tareas de segmentación semántica y por instancias en entornos urbanos.

El conjunto Cityscapes, publicado en 2016, constituyó un hito en la representación visual de ciudades europeas, proporcionando más de 25000 imágenes, de las cuales unas 5000 incluyen anotaciones densas en 30 clases diferentes. Su estructura de anotación, inspirada en el formato COCO, sentó las bases para numerosos modelos de segmentación - entre ellos DeepLab, HRNet y Mask2Former- que fueron preentrenados en este conjunto antes de ser adaptados a otros contextos mediante *transfer learning* (Sarkis 2024, págs. 178-180). Esta práctica, todavía habitual, refleja una dependencia estructural de los modelos hacia *datasets* de referencia producidos en

entornos específicos cuyas condiciones lumínicas, arquitectónicas y socioculturales acostumbran diferir de manera significativa respecto a las de otros contextos urbanos correspondientes a otras regiones del mundo (Zou et al. 2019).

El repositorio Mapillary Vistas (Neuhold et al., 2017) amplió ese horizonte geográfico y conceptual al integrar imágenes procedentes de más de 190 países, capturadas a partir de dispositivos móviles y cámaras instaladas en vehículos particulares. Su principal aportación fue introducir una mayor diversidad en las condiciones de iluminación, perspectiva y calidad óptica, lo que permitió entrenar modelos más robustos frente a la variabilidad del mundo real. Sin embargo, su carácter colaborativo también acentuó la heterogeneidad de los datos y de las convenciones de anotación, generando un desafío adicional en términos de coherencia semántica.

Por su parte, el conjunto BDD100K (Yu et al. 2020) incorporó una escala sin precedentes, con más de 100000 vídeos orientados al análisis del tráfico y la conducción autónoma. Además de las tareas de segmentación, BDD100K introdujo dimensiones temporales y multimodales —como anotaciones de trayectorias y condiciones meteorológicas—, anticipando el giro hacia *datasets* más ricos en contexto y en metadatos.

Más allá de estos repositorios de referencia, en los últimos años también ha proliferado el uso de fuentes masivas de imágenes capturadas por plataformas como Google Street View (GSV), que ofrecen una cobertura territorial más diversa que los *benchmarks*. Este recurso ha permitido a numerosos proyectos de investigación generar *datasets* urbanos de bajo coste, empleando técnicas de descarga y muestreo automatizado para la creación de conjuntos de entrenamiento (Laohaprapanon, Ortleb y Sood 2018; Weld et al. 2019; Hosseini, Miranda et al. 2022; Choi, Ku y Lee 2022). Sin embargo, el uso de estas fuentes también plantea limitaciones metodológicas relevantes: las imágenes de GSV carecen de metadatos precisos sobre condiciones de captura, presentan variaciones notables en resolución y punto de vista además de plantear el problema fundamental - común por todos los grandes conjuntos de datos hasta ahora citados- que, al tratarse de vistas tomadas desde un vehículo que circula por la calzada, tanto los vehículos estacionados (Hosseini, Miranda et al. 2022, págs. 9-10), la vegetación o cualquier tipo de mobiliario representan obstáculos similares para el algoritmo, introduciendo un sesgo sistémico en el conjunto de entrenamiento.

En paralelo, la aparición de conjuntos de datos a escala fundacional como SA-1B (Segment Anything 1-Billion) (Kirillov et al. 2023) ha transformado de manera radical el modo en que se conciben las bases de entrenamiento. Este conjunto, compuesto por más de mil millones de máscaras segmentadas en 11 millones de imágenes, constituía el mayor esfuerzo de anotación semiautomática realizado hasta la fecha²². Generado mediante una combinación de anotación humana y segmentación automatizada con el modelo SAM (Segment Anything Model), SA-1B

²²Meta FAIR lanzó en 2024 SAM-2 con un conjunto aún mayor, SA-5B (Ravi et al. 2024).

facilita la introducción de un nuevo paradigma en el que los *datasets* dejan de ser productos estáticos y cerrados para convertirse en infraestructuras dinámicas de entrenamiento continuo, que son los más necesarios para la mayoría de casos de uso reales²³.

Este cambio implica una tensión metodológica: si bien la escala de SA-1B ofrece una cobertura sin precedentes y permite un aprendizaje generalizable, su carácter masivo y automatizado reduce el control contextual y la trazabilidad de las anotaciones, dos factores críticos cuando se pretende aplicar los modelos resultantes a dominios específicos como el del mantenimiento del espacio público.

En consecuencia, una tendencia emergente en la investigación reciente ha sido complementar o sustituir las fuentes masivas por campañas específicas de recopilación de datos sobre el terreno, empleando cámaras calibradas (De Deijn y Bukralia 2024), sensores adicionales (Yoon, Kim y Jeong 2022) o drones (T. Wang et al. 2025) para capturar imágenes bajo condiciones controladas. Este enfoque permite garantizar la coherencia entre las condiciones de captura, la resolución espacial y los criterios de anotación, favoreciendo la creación de *datasets* adaptados a necesidades locales²⁴. En esta línea, resulta del mayor interés para nuestro caso de uso el proyecto SideSeeing de Damaceno et al. (2024) que propone una metodología y herramientas para el uso de cámaras en el arnés de un operador humano para recopilar imágenes del estado de aceras y que, a nuestro modo de ver, resulta una solución mucho más viable y metodológicamente menos sesgada que no el uso de drones (T. Wang et al. 2025) o cámaras en patines eléctricos (Gemminis 2025) pues, en ambos casos, además de reproducir los mismos sesgos sistémicos que la recopilación de escenas de Google Street View, también pueden encontrar restricciones de carácter legal que limiten su implementación.

Además, la captura propia abre la posibilidad de incorporar variables contextuales no visuales —como coordenadas geográficas precisas, hora del día, condiciones meteorológicas o tipo de pavimento—, enriqueciendo la semántica de los datos y facilitando su integración con sistemas de información geográfica (SIG). En el caso concreto de la monitorización del espacio público, esta combinación de información visual y geoespacial resulta especialmente valiosa para vincular las observaciones a unidades físicas reales, como tramos de acera o elementos del mobiliario urbano (Damaceno et al. 2024, págs. 5-6).

En suma, el tránsito desde los *benchmarks* globales hacia la recopilación local de imágenes no debe entenderse como una sustitución, sino como un proceso de adaptación epistemológica: los modelos preentrenados sobre conjuntos como Cityscapes, Mapillary Vistas o SA-1B ofrecen

²³Sarkis (2024, pág. 198) advierte que un conjunto de datos de más de 12 meses de antigüedad probablemente ya no representa el dominio real.

²⁴Para el caso de Barcelona existe alojado en Roboflow el llamado *Barcelona Streets Dataset* (BielGlasses 2024) que, si bien contiene más de 14000 instancias, sus criterios de anotación observables difieren notablemente de los de este proyecto, por lo que el ejercicio de comparación escapa al objetivo del presente trabajo.




Figura 2.6: Ejemplo de los límites de los datos recopilados en Google Street View en un problema de segmentación semántica: el vehículo estacionado en cordón actúa como obstáculo en esta escena y confundiendo al modelo: éste predice dos tramos de acera del mismo material con máscaras y clasificaciones distintas (Hosseini, Miranda et al. 2022).

un punto de partida necesario, pero su aplicación fiable a contextos urbanos específicos requiere conjuntos de datos propios que reflejen las particularidades del entorno físico y sociocultural en el que se desea intervenir. El presente proyecto se inscribe precisamente en esta línea, al proponer la creación del Banco de Imágenes de Anotaciones de Aceras (BIAA) como un recurso estructurado para la mejora de la monitorización y mantenimiento del espacio público en Barcelona.

3.2. La anotación

A pesar de la centralidad que ocupa en todo el ciclo de vida de los datos, la anotación ha recibido históricamente una atención limitada en la literatura sobre visión computacional²⁵. La mayoría de los estudios se han concentrado en el desarrollo de arquitecturas, algoritmos y métricas de evaluación, relegando a un segundo plano los procesos que determinan cómo se construyen las etiquetas y, con ellas, los propios significados que los modelos aprenden a reconocer. Más allá de las críticas a conjuntos de datos concretos como ha sido el caso de ImageNet (Denton et al. 2021; Paullada et al. 2021), la obra reciente de Sarkis (2024) constituye una excepción notable: al situar la anotación en el centro de la epistemología del aprendizaje profundo, revela el papel decisivo que desempeña en la calidad, robustez y validez de los modelos.

²⁵Resulta frecuente en la literatura académica que las referencias a la anotación sean anecdóticas o directamente ausentes. En cambio, los estudios más sólidos sí suelen dedicar más atención a esta cuestión, como es en el caso de Kirillov et al. (2023) para el lanzamiento de Segment Anything. Sorprendentemente, apenas se dedica espacio a esta cuestión en los artículos de Cityscapes (Cordts et al. 2016), Mapillary Vistas (Neuhold et al. 2017) y BDD100K (Yu et al. 2020), más allá de compartir algunos indicadores estadísticos sobre la distribución de etiquetas. Una notable excepción la encontramos en el caso del conjunto de datos LVIS que sí hacen un análisis estadístico más riguroso a partir de los metadatos (Gupta, Dollár y Girshik 2019).

Desde esta perspectiva, anotar no consiste únicamente en etiquetar imágenes, sino en traducir fragmentos del mundo real y del conocimiento humano a una estructura de información interpretable por el modelo (Sarkis 2024, pág. 2). Esta operación, en apariencia técnica, encierra un conjunto de decisiones conceptuales, semánticas y metodológicas que condicionan la manera en que los algoritmos aprenden a representar la realidad²⁶. En otras palabras, la anotación constituye una mediación epistemológica: fija los límites de lo que el modelo puede conocer²⁷.

Sin embargo, la práctica real de la anotación dista mucho de ser homogénea. La literatura reciente ha documentado las tensiones entre eficiencia y exhaustividad, entre automatización y control humano, así como la tendencia creciente a delegar parcialmente el etiquetado en modelos previos (pre-annotation loops) o en sistemas de segmentación automática como SAM (Kirillov et al. 2023). Estas estrategias buscan reducir el coste temporal del proceso, pero también introducen nuevos tipos de sesgos derivados de la retroalimentación entre modelos, lo que puede afectar a la diversidad y fiabilidad de las anotaciones. En esta línea, A. Sarkis subraya la necesidad de garantizar siempre lo que denomina su *human alignment*, no limitándose a repetir una representación exacta si no enderezar los resultados no supervisados (Sarkis 2024, pág. 26).

En el caso de la segmentación, la anotación adquiere un grado adicional de complejidad. Cada píxel debe ser asignado a una clase o instancia, lo que exige un equilibrio entre la precisión geométrica y la consistencia semántica. Este proceso implica no solo decisiones sobre los límites de los objetos, sino también sobre su nivel de granularidad: qué se considera una unidad relevante (por ejemplo, una pieza de pavimento, un bordillo o un tramo completo de acera). La definición de estas unidades no es trivial y depende directamente del propósito analítico del *dataset*, condicionando tanto las métricas de evaluación como la interpretación de los resultados.

Asimismo, la anotación no es una tarea neutral desde el punto de vista cognitivo ni social. Como señalan Denton et al. (2021), los equipos de anotadores trabajan bajo supuestos culturales, expectativas perceptivas y criterios operativos que influyen en la coherencia final del conjunto de datos. De ahí a la necesidad de disponer de definiciones a nivel de organización que se sustenten en conocimiento experto, especialmente en el caso de la implementación de herramientas especializadas (Sarkis 2024, págs. 17-18).

Frente a estos retos, se han propuesto diversos enfoques híbridos que combinan la anotación manual y la automática, optimizando el esfuerzo humano sin sacrificar precisión. Ejemplos recientes incluyen sistemas *human-in-the-loop*, donde el anotador valida o corrige las máscaras generadas por un modelo, o estrategias de *active learning* que priorizan las imágenes más infor-

²⁶En la obra Sarkis (2024) se dedican los capítulos 3º y 6º específicamente a esta como estructurar y construir las definiciones que sustentarán la tarea del anotador de datos.

²⁷Especialmente, recuerda que el software “only has the context that is programmed into it, be it through data or lines of code” (Sarkis 2024, pág. 6).

mativas para su revisión. Estas metodologías resultan especialmente pertinentes para dominios urbanos, donde la variabilidad visual es alta y las clases relevantes son finitas pero complejas.

En este contexto, el presente proyecto adopta un enfoque iterativo de anotación semiautomática (T. Wang et al. 2025, pág. 8), inspirado en los principios anteriores, con el objetivo de maximizar la coherencia espacial y semántica de las máscaras generadas. La anotación, por tanto, no se concibe aquí como una etapa subordinada a la modelización, sino como una fase constitutiva del ciclo de aprendizaje, en la que el conocimiento experto y el conocimiento algorítmico se retroalimentan para producir representaciones más fieles y contextualizadas del entorno urbano.

4. Resumen

A lo largo de los apartados precedentes se ha revisado tanto la singularidad del problema del mantenimiento de las aceras como además la evolución de la visión computacional desde la clasificación de escenas hasta la segmentación por instancias, destacando el papel estructural del paradigma COCO y de los grandes modelos fundacionales. Esta trayectoria ha permitido comprender cómo las distintas metodologías -clasificación, detección y segmentación- han ido refinando la capacidad de los algoritmos para interpretar escenas complejas y representar de forma cada vez más precisa los componentes del espacio urbano. Este proceso de refinamiento, sin embargo, ha ido también acompañado de una creciente conciencia sobre las limitaciones inherentes a cada enfoque: la pérdida de granularidad de la clasificación, la rigidez geométrica de la detección mediante *bounding boxes* y las dificultades de la segmentación semántica para distinguir instancias individuales. En este contexto, la segmentación por instancias emerge como la aproximación más adecuada para abordar el diagnóstico y la monitorización automatizada del espacio público.

Del mismo modo, se ha subrayado que los avances metodológicos dependen de la calidad epistemológica de los datos que los sustentan. La creación de conjuntos de datos -desde los grandes repositorios globales como Cityscapes, Mapillary Vistas o SA-1B hasta las campañas locales de captura sobre el terreno- y, especialmente, su proceso de anotación, constituyen el verdadero cimiento de cualquier modelo robusto. Anotar equivale a traducir el mundo real en estructuras formales que determinan qué puede aprender el algoritmo, de ahí que la coherencia semántica y el *human alignment* sean condiciones indispensables para una modelización fiable. Sobre estas bases conceptuales y técnicas se apoya la metodología que se desarrolla en el siguiente capítulo, dedicada al diseño y construcción del Banco de Imágenes de Anotaciones de Aceras (BIAA) como infraestructura de datos para la monitorización y mantenimiento del espacio público urbano.

Capítulo 3

Materiales y métodos

El presente capítulo describe el conjunto de procedimientos empleados para abordar el problema de la detección y segmentación del pavimento de aceras en Barcelona y su área metropolitana. El objetivo metodológico consiste en evaluar si un subconjunto anotado manualmente del BIAA (Banco de Imágenes de Anotaciones de Aceras) puede servir como base para ajustar modelos de segmentación entrenados originalmente con conjuntos de datos genéricos o centrados en infraestructuras viarias distintas a la acera.

Para ello, el proceso se articula en cuatro bloques. En primer lugar, se detalla la recopilación, caracterización y primera depuración del conjunto de imágenes obtenido mediante recorridos pedestres sistemáticos¹, prestando especial atención a los metadatos asociados y a las limitaciones del dominio visual de la acera. Esta fase inicial permite entender el tipo de escena predominante y los condicionantes particulares del entorno que lo diferencian de otros escenarios urbanos.

Posteriormente, se plantea una comparación entre modelos preentrenados (DeepLabV3+, HRNet y Mask2Former) entrenados con el *dataset* Cityscapes y SAM entrenado con el *dataset* SA-1B². El propósito de esta comparación no es realizar una competición de arquitecturas, sino evaluar el impacto del dominio de entrenamiento. Estos modelos funcionan como líneas base que permiten medir la brecha entre modelos entrenados en dominios generales o vehiculares y el dominio peatonal. Contrastar ambos sirve para establecer un punto de partida crítico: qué puede y qué no puede aportar un modelo preentrenado cuando se le aplica directamente al entorno peatonal barcelonés.

A continuación, se describe el proceso de anotación del conjunto de 507 imágenes seleccionadas, justificando tanto la definición de las diez clases finales como los criterios geométricos

¹Mayoritariamente en la ciudad de Barcelona, como se tratará en el próximo apartado 3.1.

²Ambos conjuntos de datos ya han sido descritos en el anterior apartado 2.3.1.

aplicados para cada máscara y teniendo también presente el coste que esta tarea representa³. Dentro de este proceso se evalúa el papel de la preanotación semiautomática mediante SAM, cuyo uso pretende reducir el coste del etiquetado manual. El planteamiento de esta fase no se limita a describir su implementación, sino que analiza si, en el dominio específico de las aceras, SAM aporta una mejora real en tiempo y coherencia del etiquetado, o si, por el contrario, genera sobresegmentación o máscaras poco útiles para el entrenamiento supervisado.

Finalmente, el capítulo concluye con el fine-tuning de DeepLabV3 preentrenado con Cityscapes⁴, utilizando exclusivamente los datos anotados del BIAA. El objetivo de esta etapa no es obtener un modelo óptimo, sino validar si un volumen reducido de datos específicos del dominio permite corregir patrones de segmentación aprendidos previamente, especialmente aquellos derivados del sesgo de Cityscapes. Con ello, este proyecto en esta primera fase no pretende “entrenar desde cero”, sino demostrar el valor de datos locales, anotados con criterios consistentes y adaptados al dominio del pavimento peatonal.

En conjunto, la metodología implementada⁵ no busca maximizar métricas, sino cuantificar cuánto aporta el BIAA como conjunto de datos especializado para tareas de mantenimiento urbano y qué implicaciones tiene para futuros desarrollos de visión computacional orientados a la gestión de aceras. Como observa A. Sarkis, esto requiere de análisis de métricas además de la evaluación cualitativa (Sarkis 2024, pág. 177).

1. Recopilación de los datos del BIAA

El conjunto de datos empleado en este proyecto procede de la recopilación sistemática de imágenes del espacio peatonal realizadas entre junio de 2023 y mayo de 2025, conformando la primera fase del Banco de Imágenes de Anotaciones de Aceras (BIAA). La captura se llevó a cabo mediante recorridos pedestres planificados en diversos barrios de la ciudad de Barcelona y en varios municipios de su área metropolitana, con el propósito de documentar el pavimento de aceras en condiciones reales de uso, sin intervención ni selección previa del estado del entorno⁶.

³Como se expondrá en el apartado 3.3.

⁴DeepLabV3 se elige como arquitectura de referencia para el ajuste por su condición de *baseline* consolidado en segmentación semántica urbana, como ya apuntamos en el anterior apartado 2.3.1.

⁵El *dataset* de *ground truth* está disponible en nuestro repositorio en Roboflow (Ramírez Jávega 2025a), mientras los *notebooks* y demás materiales precisos para los análisis aquí compartidos están alojados en nuestro repositorio en GitHub (Ramírez Jávega 2025b).

⁶Como ya se indicó en el anterior apartado 1.5, el autor trabajó entre mayo de 2021 y febrero de 2025 en tareas relacionadas con el mantenimiento de aceras en un distrito del Ayuntamiento de Barcelona. Estas imágenes en todo momento se realizaron al margen de estas tareas laborales, aunque ocasionalmente puedan haberse usado internamente.




Figura 3.1: Distribución anual de las imágenes capturadas (*raw data*).

La elección de recorridos pedestres responde a dos motivos metodológicos. En primer lugar, esta estrategia permite registrar el punto de vista del peatón, alineado con el objetivo del proyecto, que busca analizar el deterioro del pavimento desde la experiencia de quien lo transita. En segundo lugar, evita los sesgos propios de otras fuentes frecuentes en visión urbana —como, entre otros, Google Street View o sensores montados en vehículos—, que tienden a privilegiar la calzada, entre otros motivos⁷.

En todas las imágenes se empleó el mismo dispositivo de telefonía móvil Redmi Note 8 (2021) con cámara ultra gran angular de 48 MP y equipado con la aplicación Solocator (Solocator 2025), que permite registrar metadatos geográficos y técnicos asociados a cada imagen, incluyendo coordenadas GPS y fecha. Este contenido resulta esencial para organizar y caracterizar espacialmente el conjunto de datos, así como para su potencial integración futura con sistemas GIS municipales. En total fueron capturadas 3302 imágenes que se corresponderían con 1801 escenas únicas, entendidas como una misma localización capturada desde diferentes distancias o perspectivas.



Figura 3.2: Ejemplos del recorte aplicado a las imágenes (*raw data*) como preprocesamiento inicial.

Sin embargo, la aplicación incluye en la propia imagen una cabecera con información su-

⁷Ver la discusión ya planteada en el anterior apartado 2.3.2.

perpuesta de los metadatos capturados. Dado que esta cabecera ocupa parte del fotograma y puede inducir artefactos en el entrenamiento de modelos de segmentación —al introducir texto y elementos gráficos que no forman parte del dominio visual— se optó por eliminar dicha franja superior mediante un primer preprocesamiento sistemático, manteniendo intacto el resto de la imagen. Esta operación no altera el contenido relevante para la segmentación (ver ejemplos de la Figura 3.2), pero sí asegura que el modelo no incorpore patrones relativos a dicha cabecera ni los interprete como objetos a segmentar.

El conjunto incorpora ejemplos tanto de pavimento en buen estado como de incidencias diversas —roturas, hundimientos, desplazamientos, desgaste— aunque estas últimas no fueron buscadas de forma dirigida, sino recogidas en el flujo natural de la observación incidental aunque sí intentando obtener dichas imágenes en franjas horarias y condiciones meteorológicas diversas con el fin de disponer de muestras representativas de situaciones correspondientes al mundo real.




Figura 3.3: Mapa de la distribución geográfica de las imágenes capturadas (*raw data*).

En cambio, al ser el objetivo de este proyecto la captura de muestras representativas de tipos de pavimento y también desde el punto de vista funcional, no resulta problemático en esta fase inicial que la gran mayoría de imágenes se correspondan con la ciudad Barcelona (ver Tabla 3.1) ni tampoco que estas se concentren mayoritariamente en el distrito de Horta-Guinardó (ver Anexo B, Figura B.3).

Esta diversidad contextual no persigue maximizar la variabilidad estética, sino garantizar

Tabla 3.1: Distribución de imágenes por municipio.

Municipio	Cantidad de imágenes
Barcelona	2826
Esplugues de Llobregat	1
L’Hospitalet de Llobregat	73
Sant Adrià de Besòs	30
Santa Coloma de Gramenet	15
Vilassar de Mar	26
Mataró	133
Pineda de Mar	25
Malgrat de Mar	173

que el conjunto represente los desafíos reales que un modelo enfrentará al segmentar pavimentos urbanos: irregularidades geométricas, obstrucciones, variaciones de iluminación y heterogeneidad material. En consecuencia, la recopilación de datos se concibe como la primera capa de un pipeline orientado al aprendizaje robusto del dominio peatonal.

2. Comparación entre modelos preentrenados con Cityscapes y SAM (SA-1B)

Con el fin de evaluar la transferibilidad de modelos de segmentación al dominio peatonal, se realizó una comparación inicial entre tres arquitecturas de segmentación semántica ampliamente utilizadas como DeepLabV3+⁸, HRNet⁹ y Mask2Former¹⁰ preentrenadas con el conjunto Cityscapes, y el modelo de segmentación por instancias SAM (Segment Anything Model), entrenado con el dataset SA-1B.

Esta comparación no pretende determinar qué arquitectura es “mejor”, sino medir el impacto del dominio de entrenamiento sobre la segmentación del pavimento de aceras. Cityscapes constituye un referente en visión urbana, pero su diseño prioriza escenas vehiculares: la calzada ocupa la región central de la imagen, los peatones y bordes son elementos secundarios y la representación del pavimento peatonal es limitada y heterogénea. En consecuencia, estos modelos funcionan como *líneas base* que permiten evaluar hasta qué punto un modelo entrenado con un contexto vehicular es reutilizable para la vía pública en Barcelona y su área metropolitana.

Por contraste, SAM ha sido entrenado con el conjunto masivo SA-1B, cuya cobertura es generalista y no especializada en infraestructuras urbanas. Debido a ello, su rendimiento depende de la configuración de los hiperparámetros que regulan la generación de máscaras. Siguiendo el

⁸Con *backbone* Mobilenet (Fang, Gongfan 2022).

⁹Con *backbone* HRNetV2-W48 (J. Wang et al. 2021).

¹⁰Con *backbone* Swin Small (Facebook Research 2021).

planteamiento de Almazroey, Jarraya y Alnanih (2025), se modificaron los valores por defecto para disminuir la sobresegmentación y reducir el tiempo de inferencia en el modo *Segment Everything*, donde el modelo produce máscaras sin instrucciones o puntos de entrada del usuario. Para ello, se escogió el *backbone* base debido a los límites del *hardware* disponible y que se detalla a continuación.

En SAM, el parámetro *points_per_side* controla la densidad de propuestas de máscara a partir de una cuadrícula de muestreo; los umbrales *pred_iou_thresh* y *stability_score_thresh* actúan como filtros de calidad, descartando predicciones inciertas; y la combinación de *crop_n_layers* y *min_mask_region_area* limita la segmentación multiescala y elimina regiones irrelevantes o demasiado pequeñas.

El objetivo de nuestra parametrización experimental es tanto eliminar la segmentación de objetos de reducido tamaño, como la suciedad o aves - que requirieran también de más muestras para su identificación-, pero explorando la posibilidad que SAM sugiriese máscaras que, de otro modo, no se incluirían en el resultado final por sus bajas métricas de predicción. El detalle de la parametrización por defecto y la escogida para este experimento puede consultarse en la Tabla 3.2:

Tabla 3.2: Parametrización de Segment Anything Model (SAM).

Parámetro	Valor por defecto	Valor experimental
points_per_side	32	3
pred_iou_threshold	0.86	0.75
stability_score_thresh	0.92	0.55
crop_n_layers	1	0
crop_n_points_downscale_factor	2	0
min_mask_region_area	100	41000

Para el experimento, se utilizaron imágenes del BIAA aplicando el recorte descrito en el apartado anterior y, adicionalmente, una reducción uniforme de resolución del 50 % para evaluar si el *downsampling* afectaba al tiempo de inferencia y a la calidad de segmentación en SAM. Los modelos preentrenados con Cityscapes fueron evaluados en un conjunto aleatorio de 20 observaciones, correspondiente a escenas representativas de los *benchmarks* Cityscapes - solamente de su conjunto de test-, Mapillary Vistas y BDD100K como también del BIAA. Al no disponer entonces de ningún conjunto *ground truth* de este último, se valoró sólo tomar en consideración el mIoU de la predicción de máscaras en el caso de SAM además de los *logits* para el caso de los *benchmarks*. En referencia al hardware, en éste y los experimentos descritos en esta memoria se ha utilizado el mismo equipo con CPU AMD Ryzen 7 7840HS (5.1GHz) con 64 GB de RAM y con GPU GeForce RTX 4050 con 8 GB de VRAM.

De este modo, la comparación busca responder dos cuestiones analíticas:

1. ¿Hasta qué punto los modelos entrenados con Cityscapes son aplicables al dominio pea-

tonal de Barcelona y su área metropolitana?

2. ¿SAM muestra adaptación al dominio peatonal sin haber sido entrenado específicamente para ello?

Estas preguntas permiten establecer el estado inicial de desempeño antes de introducir datos locales anotados, que se analizarán en los siguientes apartados.

3. La anotación

El rendimiento de cualquier modelo supervisado de segmentación depende, además del volumen y variabilidad de los datos de su conjunto de entrenamiento, también de la calidad del conjunto de datos anotado que se emplee para su entrenamiento. En el caso del BIAA, el objetivo de la anotación no es únicamente etiquetar objetos urbanos visibles en la acera, sino hacerlo siguiendo criterios geométricos, funcionales y consistentes que permitan describir con precisión las unidades físicas que pueden ser objeto de mantenimiento. Por esta razón, se optó por una anotación manual detallada realizada con la herramienta *Labelme* (Labelme 2025) en su versión gratuita, ampliamente utilizada en investigación por su soporte para máscaras poligonales, compatibilidad con flujos de trabajo personalizados y generación directa de anotaciones en formato JSON aptas para preprocesamiento y conversión a estructuras utilizadas en bibliotecas de visión computacional. Por otro lado, como A. Sarkis aconseja, para proyectos a pequeña escala - *Point solutions* como el presente- que se deben ejecutar en local es mejor utilizar herramientas que no requieran de configuraciones complejas ni infraestructura de almacenamiento en la nube (Sarkis 2024, págs. 54-55).

La elección de *Labelme* responde además a una necesidad práctica: el dominio peatonal presenta geometrías irregulares y discontinuidades —losetas desplazadas, bordillos fracturados, grietas, cunetas y tapas de servicio— que requieren trazados precisos y que no pueden ser descritos adecuadamente mediante *bounding boxes* o aproximaciones genéricas. De este modo, se priorizó la calidad de las máscaras por encima de la velocidad de etiquetado para garantizar un conjunto anotado fiable para evaluar la adaptación de los modelos al dominio.




Figura 3.4: Trade-off descrito por A. Sarkis (Sarkis 2024, pág. 72) entre tiempo y calidad en la anotación.

No obstante, la anotación manual implicó un coste temporal significativo. El *ground truth* de 507 imágenes¹¹ requirió un total de 2367 minutos de trabajo, equivalente a **39,45 horas** de anotación manual, sin incluir revisiones ni correcciones posteriores. Dicho esfuerzo evidencia que el escalado del *dataset* resulta inviable en el marco de un proyecto individual o, alternativamente sin algún tipo de asistente automático o semiautomático. Por este motivo, dentro del proceso de anotación se planteó evaluar el papel de SAM como herramienta de preanotación, analizando si su uso reduce sustancialmente el tiempo de etiquetado y mejora la coherencia del proceso o, por el contrario, si introduce sobresegmentación, máscaras redundantes o estructuras no ajustadas a dominio para el entrenamiento supervisado.

Por tanto, esta fase no se limita únicamente a describir el proceso de anotación, sino que examina si la incorporación de SAM puede constituir una estrategia viable para escalar el BIAA en futuras iteraciones, optimizando el balance entre precisión y coste en un flujo de trabajo orientado a la gestión del mantenimiento urbano.

3.1. Criterios de anotación del BIAA

La anotación del BIAA se ha diseñado con el objetivo de capturar las unidades físicas relevantes para el mantenimiento del pavimento peatonal, garantizando que los modelos basados en aprendizaje supervisado puedan aprender a delimitar objetos cuya forma, función y material condicionan los procesos de inspección y reparación en la vía pública. En consecuencia, la elaboración de máscaras no responde a una simple clasificación visual, sino a una segmentación funcional, es decir, una delimitación que permita diferenciar elementos que implican actuaciones técnicas distintas en el espacio peatonal mediante el uso de polígonos (Sarkis 2024, pág. 94).

¹¹Esta cantidad responde a las limitaciones de tiempo disponible para poder realizar esta tarea. En su selección manual se priorizaron tanto las escenas en condiciones nocturnas como en contextos de humedad en el pavimento al apreciarse en la Figura 3.2 del Anexo B que este tipo de escenas podían resultar aún más minimizadas en una selección aleatoria automática. El conjunto de *ground truth* está alojado públicamente en Roboflow: https://universe.roboflow.com/biaa/biaa_v100_gt.

Tabla 3.3: Etiquetas del BIAA y su relevancia para tareas de mantenimiento urbano.

Etiqueta	Descripción
sidewalk_tiles	Pavimento modular, ya sea <i>panot</i> , losas o pavimento modular singular. Abarca también las piezas de vados peatonales y de vehículos. Se traza una máscara distinta en función del tipo de material.
sidewalk_asphalt	Pavimento continuo en contextos de acera. Incluye tanto pavimentación con asfalto como también hormigón. Se traza una máscara distinta en función del tipo de material.
roadway	La calzada pavimentada.
curb_edge	Bordillo o piezas de pavimento que, generalmente, bordean el pavimento. Se traza una máscara distinta en función del tipo de material.
gutter	Zona de evacuación de agua o cuneta. Puede estar constituida por piezas de pavimento - <i>rigola</i> - o asfalto. Se traza una máscara distinta en función del tipo de material.
drainage_inlet	Infraestructura de drenaje. Abarca tanto la pieza metálica que impide la entrada de objetos de gran tamaño en el acantarillado como también la entrada correspondiente en el bordillo, en la acera o la calzada. Se trazan máscaras de cada objeto.
access_cover	Vías de acceso al alcantarillado, público o privado, además de también a instalaciones de suministros soterrados. Se trazan máscaras de cada objeto.
tree_pit	Pieza de pavimento que comprende la sección de tierra compactada donde echa raíz el arbolado en contextos de acera. También abarca los espacios ajardinados integrados en acera roeados con un bordillo. Se trazan máscaras de cada objeto.
vegetation	Se circunscribe solamente al arbolado y la vegetación que crece en espacios ajardinados específicos. Se traza una máscara única cuando se presentan en el mismo contexto arbolado y vegetación baja.
street_furniture	Mobiliario urbano público como la señalización viaria, bancos, paradas de autobús, hitos y piezas protectoras de carriles bici. También abarca el mobiliario privado que se encuentre en la acera como el relacionado con las terrazas de bar. Se trazan máscaras de cada objeto.

Por otro lado, debido a las limitaciones de los recursos disponibles, en la presente fase de desarrollo de este proyecto se ha procedido a implementar la segmentación por instancias solamente en algunas clases como pueden ser el mobiliario urbano o las tapas de registro y alcantarillado. Esta decisión se justifica en el hecho, como ya apuntó A. Sarkis, la segmentación por objetos resulta una ampliación en el detalle - y también en la tarea de anotación- de la segmentación semántica (Sarkis [2024](#), págs. 90-91, 134). En nuestro caso concreto, lo imple-

mentamos des de la perspectiva de poder escalar el proyecto en el futuro y, por lo tanto, en esta fase resulta suficiente poder etiquetar los objetos con etiquetas más genéricas. En futuras iteraciones, estas podrán tener mayor granularidad.

Además de las 10 clases anteriores, se incorporó una máscara de exclusión o *ignore*, asignada a regiones que no deben participar en el aprendizaje ni en la evaluación métrica. Su uso se justifica por tres motivos:

1. Eliminación de objetos irrelevantes para mantenimiento como vehículos, animales domésticos o personas parcialmente o totalmente visibles.
2. Prevención de sesgos indeseados, evitando que el modelo aprenda a segmentar estructuras efímeras, no relacionadas con el pavimento o con escaso valor para inspección.
3. El llamado *background*: fachadas de edificios, el cielo, espacios ajardinados que no forman parte de la acera como parques y jardines.

Así, esta clase no aumenta precisión, sino que protege el valor del *dataset* al garantizar que las métricas reflejen únicamente decisiones anotadas con certeza y relevancia funcional. Finalmente, existe otra tipología de objetos que no se han etiquetado en modo alguno, como son las aves o la suciedad, para que así el modelo aprenda a tratarlos como ruido.

A diferencia de otros dominios donde una máscara representa objetos separados entre sí - como sería el caso generalista de SAM-, el espacio urbano presenta elementos que se apoyan físicamente unos sobre otros. Estos objetos pueden aparecer en una imagen bidimensional o bien ocultos o bien truncados, como observa A. Sarkis (ver Figura 3.5):




Figura 3.5: Demostración de los fenómenos de ocultación y truncado de objetos en una imagen (Sarkis 2024, pág. 71).

Por ello, se permiten y se trazan máscaras superpuestas cuando se trata de objetos que ocultan las clases de la acera - *sidewalk_tiles* y *sidewalk_asphalt*-, la calzada - *roadway*-, el bordillo - *curb_edge*-, la cuneta - *gutter*- y el alcorque - *tree_pit*-. En el caso del resto de clases, se permite su oclusión. Entendemos que este criterio permite a los modelos aprender a distinguir materiales y bordes funcionales alineados con nuestro caso de uso: el mantenimiento

de pavimento. Y evitando que estos puedan verse segmentados no sólo por fronteras visuales, lo cual es esencial para generar segmentaciones útiles.




Figura 3.6: Distribución de las instancias de cada clase anotada en el conjunto *ground truth*.

Por otro lado, a raíz de la detección en el experimento descrito en el anterior apartado 3.2 y los resultados descritos en el apartado 4.1, se ha tenido también en consideración el fenómeno de la dependencia entre clases en los modelos preentrenados con el *dataset* Cityscapes. Para ello, a la hora de transformar las máscaras en archivos PNG para el entrenamiento de modelos basados en la arquitectura DeepLabV3¹², hemos implementado esta priorización en los archivos que servirán de entrada en el entrenamiento del modelo (ver Figura 3.7).

De este modo, la organización de las máscaras no sólo permite segmentar las clases relevantes para el mantenimiento, sino también observar empíricamente cómo interactúan entre sí en escenas reales, lo que posibilita evaluar en fases posteriores si alguna clase debería subdividirse, fusionarse o ampliarse para mejorar la representación del dominio peatonal.

¹²Ver el posterior apartado 3.4.




Figura 3.7: Priorización de las máscaras en el proceso de rasterización.

3.2. Preanotación con SAM

SAM constituye, en teoría, un candidato atractivo para la preanotación, dado que es capaz de segmentar objetos presentes en una imagen sin instrucciones explícitas (modo *Segment Everything*). Sin embargo, y tal como se señaló en el apartado 2.2.5, su comportamiento puede depender tanto de la densidad de propuestas de máscara y también de los filtros de calidad aplicados. Así, el resultado esperado sería que SAM no aportase conocimiento semántico específico sobre el pavimento urbano, sino que genere hipótesis geométricas sobre contornos visualmente detectables, que pueden resultar útiles o, por el contrario, inducir sobresegmentación o confusión con elementos no relevantes.

Con el propósito de ajustar su funcionamiento al dominio analizado, se adoptó la configuración de parámetros sugerida por Almazroey, Jarraya y Alnanih (2025) que implementamos en el experimento descrito en el apartado 3.2 (ver 3.2). Esta parametrización se aplicó exclusivamente para generar máscaras candidatas que posteriormente debían ser aceptadas, modificadas o eliminadas manualmente mediante *Labelme*. Por tanto, SAM no sustituyó la labor de anotación, sino que actuó como generador inicial de polígonos. En paralelo, se registró el tiempo requerido para corregir o descartar las máscaras generadas¹³, con el objetivo de determinar si el flujo de trabajo asistido resultaba más eficiente que la anotación manual directa¹⁴. Finalmente, no solo por limitaciones temporales, sino para poder evaluar el rendimiento del asistente de manera estadísticamente controlada, solamente se procedió a realizar este experimento con 400 imágenes del conjunto de *ground truth* (78,9% del total) y calculándose el consiguiente error muestral del 4.9%. Además de registrar el tiempo de corrección y descarte de máscaras, este subconjunto fue enriquecido con anotaciones adicionales sobre las condiciones de captura de la escena con el fin de analizar si estos factores influyen en la utilidad real de SAM como asisten-

¹³Estas métricas son las que, entre otras, sugiere A. Sarkis para poder analizar la tarea de anotación (Sarkis 2024, pág. 143).

¹⁴Como ya se ha indicado al inicio del capítulo 3, requirió de 2367 minutos (39,45 horas) de trabajo.

te de preanotación: perspectiva, iluminación nocturna, humedad del pavimento, presencia de anomalías y aparición de figuras humanas.

De este modo, la preanotación con SAM no se plantea como una mejora automática, sino como una pregunta experimental: ¿en el dominio del pavimento peatonal, SAM reduce el coste de anotación sin introducir errores que aumenten el trabajo posterior? La respuesta a esta cuestión se abordará en el apartado 4.2 a través del análisis combinado de tiempos, coherencia geométrica y utilidad real de las máscaras generadas.

4. Fine-tuning de DeepLabV3 preentrenado con Cityscapes usando datos del BIAA

El último bloque metodológico consiste en el ajuste fino (fine-tuning) de la arquitectura DeepLabV3, utilizando como punto de partida los pesos preentrenados con Cityscapes y empleando como datos supervisados las anotaciones del BIAA. El propósito de esta etapa no es obtener un modelo óptimo de segmentación de pavimentos, sino evaluar si un volumen reducido de datos locales, rigurosamente anotados, es capaz de corregir o reorientar sesgos derivados del entrenamiento previo en un dominio principalmente vehicular.

DeepLabV3 se adopta como arquitectura de referencia por dos motivos:

1. Su relevancia como *baseline* consolidado en segmentación semántica urbana.
2. La disponibilidad de pesos preentrenados con Cityscapes, que permiten medir explícitamente el impacto de incorporar conocimiento local mediante *fine-tuning*. Este diseño experimental permite observar cómo un modelo entrenado para reconocer fundamentalmente la calzada y el tráfico urbano puede reorientar sus predicciones hacia elementos peatonales, como *panots*, *rigolas*, bordillos o alcorques.

Para el entrenamiento, el conjunto anotado de 507 imágenes fue dividido en tres subconjuntos mediante selección aleatoria: 354 imágenes para el subconjunto de entrenamiento (69,8 %), 77 para el subconjunto de validación (15,2 %) y 76 para el subconjunto de test (15,0 %). Todas las imágenes fueron normalizadas a resolución de 768×768 por ser la resolución más cercana a la moda del conjunto (ver Figura B.5 en el Anexo C), minimizando la distorsión geométrica y la pérdida de detalle. Del mismo modo, se implementó una conservadora aumentación de datos consistente en revertir horizontalmente las imágenes de los subconjuntos de entrenamiento y validación - *flipping*- (Géron 2023, págs. 500, 519) entendiendo que esta era una representación realista de este dominio, evitando otras como la rotación, el escalado agresivo o cambios de luminosidad al no representar transformaciones plausibles en el dominio peatonal: por ejemplo,

invertir 180° haría que los árboles parezcan crecer hacia abajo y, por lo tanto, un patrón que no es deseable que aprenda el modelo.

En relación al modelo preentrenado de la arquitectura DeepLabV3, hemos escogido por su sencillez el modelo publicado por Koushik (2025) en HuggingFace que utilizó el *backbone* ResNet-50 con resolución de entrada 360x720 coherente con las imágenes del *dataset* Cityscapes, cuyas imágenes son todas rectangulares; el optimizador Adam en el entrenamiento de 1 época de duración y con pérdida final de 0.5157 obtenida mediante CrossEntropyLoss. La única métrica aportada fue la precisión por píxel de 0.7805.

Siguiendo las mejores prácticas propuesta en el artículo seminal de la arquitectura DeepLab (L.-C. Chen et al. 2018, pág. 7), se empleó la tasa de aprendizaje de 1×10^{-4} , acompañada de una estrategia de *early stopping* con paciencia de 20 épocas evitando tanto el sobreajuste como la inestabilidad típica de entrenamientos con *datasets* reducidos. Asimismo, se evaluaron distintas combinaciones de hiperparámetros mediante búsqueda orientada (*grid search*) con los optimizadores Adam y AdamW - ambos son habituales en la arquitectura DeepLab-, y límites máximos de 90 y 135 épocas para dar oportunidad que el entrenamiento pudiese dar resultados prometedores, generando así cuatro posibles configuraciones. El modelo final seleccionado fue aquel que maximizó la mIoU en el conjunto de validación y, como criterio secundario para el *early stopping*, minimizando también la pérdida calculada con el subconjunto de validación calculada con CrossEntropyLoss.

El objeto del subconjunto de test en este experimento será documentar empíricamente hasta qué punto la aportación de datos locales modifica el comportamiento de un modelo generalista, identificando tanto mejoras como errores sistemáticos persistentes. Esta evaluación comparativa será desarrollada en el próximo apartado 4.3 a través de métricas cuantitativas y análisis cualitativo orientado a determinar la utilidad del modelo para tareas reales de monitorización del pavimento.

Capítulo 4

Resultados experimentales

Este capítulo presenta los resultados obtenidos en las tres fases metodológicas desarrolladas: la comparación de modelos preentrenados, la evaluación del proceso de anotación y el ajuste fino de DeepLabV3 con datos del BIAA. El objetivo no es únicamente medir el desempeño numérico de los modelos, sino interpretar cómo el dominio peatonal condiciona la segmentación y hasta qué punto la incorporación de datos locales modifica el comportamiento de arquitecturas entrenadas en escenarios urbanos generalistas o centrados en la calzada.

En consecuencia, los resultados se analizan tanto desde métricas cuantitativas como a partir de una evaluación cualitativa de las máscaras generadas, destacando patrones de error, mejoras atribuibles al *fine-tuning* y el potencial de ampliación del *dataset* para futuras iteraciones.

1. Resultados de la comparación entre modelos preentrenados con Cityscapes y SAM (SA-1B)

Los modelos preentrenados, por un lado, con Cityscapes como DeepLabV3+, HRNet y Mask2Former; y, por otro lado, el modelo SAM entrenado con SA-1B fueron evaluados sobre un conjunto heterogéneo de imágenes que incluía escenas capturadas en Barcelona y su área metropolitana, además de un muestreo aleatorio de imágenes correspondientes a los *benchmarks* Cityscapes, Mapillary Vistas y BDD100K. El objetivo fue analizar su capacidad de transferir conocimiento a un dominio que prioriza el pavimento de las aceras, ausente o marginal en los *datasets* originales.

Los resultados confirman un comportamiento desigual entre arquitecturas, condicionado más por el dominio de entrenamiento que por la sofisticación del modelo. En el caso de los modelos entrenados con Cityscapes, se observó sistemáticamente la tendencia a segmentar la calzada como región central dominante, relegando el pavimento peatonal a bordes secundarios o incluso

asignándolo erróneamente como calzada en contextos donde el encuadre visual priorizaba el suelo (ver Anexo C, Figuras C.1, C.2, C.3 y C.4).

Esto se acentúa con el fenómeno de la correlación espuria entre clases. Este comportamiento se manifiesta cuando la predicción de una categoría depende implícitamente de la presencia o ausencia de otra, no por sus propiedades visuales intrínsecas, sino por patrones espaciales aprendidos del *dataset* de origen y que son fruto de su escasa variabilidad¹.

En el caso de Cityscapes, el modelo ha interiorizado que la calzada ocupa sistemáticamente la región central de la escena, seguida de bordes laterales que suelen corresponder a aceras, con objetos verticales delimitando el espacio. O bien, identificando sistemáticamente la región de pixels alrededor de una figura humana como acera, independientemente de si esta se encuentra en la calzada o en la acera. Como consecuencia, en el dominio peatonal del BIAA, donde la acera puede ocupar toda la imagen y la calzada puede no aparecer, estos modelos tienden a reinterpretar el pavimento peatonal como calzada, desplazando erróneamente los límites del bordillo, de la cuneta y del arbolado. Este fenómeno no solo compromete la segmentación, sino que introduce errores sistemáticos.

Aunque Mask2Former produjo segmentaciones más definidas en algunos casos y su rendimiento en clases horizontales de aceras fue más consistente, también se observó la fuerte correlación espuria entre las clases de *sidewalk* y las correspondientes a figuras humanas, hasta el punto de confundir aceras sin peatones con la calzada y contextos de peatones cruzando la calzada como acera, lo que refuerza nuestra interpretación del peso del sesgo de entrenamiento en el rendimiento de los modelos preentrenados con Cityscapes (ver Anexo C, Figuras C.5 y C.6).

La implementación de las diversas parametrizaciones de SAM, basada en una calibración en una imagen de resolución 816x720 (ver Anexo C, Figura C.7), reveló una reducción del tiempo de inferencia de 12.67 segundos a solamente 0.67, con una reducción del mIoU de la predicción de 0.95 a 0.925; y, en el caso de la imagen reducida a resolución 408x360, el tiempo de inferencia fue de 10.44 segundos a solamente 0.54 y el mIoU de la predicción de 0.949 a 0.921. Sin embargo, también reveló dos comportamientos relevantes:

- Tendencia a proponer contornos geoméricamente correctos en superficies homogéneas, especialmente en pavimento modular de aceras.
- Generación de predicciones redundantes o fragmentadas con el *panot*, produciendo sobre-segmentación sin significación humana.

Este comportamiento dual sugiere que SAM no puede ser utilizado como herramienta de

¹Como ya se apuntó en el anterior apartado 2.2.4 al tratar tanto la *epistemic uncertainty* como los *domain gap*.

segmentación final (ver Anexo C, Figura C.8), pero sí como candidato a preanotación cuando el objetivo es delimitar polígonos que posteriormente serán depurados manualmente (Sarkis 2024, págs. 242-243, 249-254), tal como se analizará en el apartado 4.3.2.

En conjunto, los resultados de esta comparación indican que:

1. Los modelos entrenados con Cityscapes no trasladan adecuadamente su conocimiento al pavimento peatonal, incluso cuando reconocen correctamente elementos urbanos verticales o de calzada;
2. SAM, entrenado con el conjunto de datos SA-1B, aporta geometría pero no semántica, lo cual lo sitúa como auxiliar potencial de anotación, pero no como modelo de segmentación aplicable al mantenimiento urbano y, por lo tanto, justificando la pertinencia de los datos del BIAA.

Estas observaciones constituyen el punto de partida experimental que justifica el *fine-tuning* con datos del BIAA, desarrollado en el apartado 4.3.

2. Resultados del proceso de anotación

Como ya se indicó, el tiempo necesario para la creación y etiquetado manuales de las máscaras fue de 2367 minutos (39.45 horas). Aunque la media del tiempo necesario para anotar cada imagen fue de 4.67 minutos, la duración modal fue de solamente 2 minutos (ver Figura 4.1).




Figura 4.1: Variancia y distribución del tiempo de anotación manual del conjunto *ground truth*, indicándose los cuartiles.

La clasificación intercuartiles observada se corresponde con los rangos de 1-2, 3-4, 5-6 y 7 o más minutos necesarios para anotar la imagen correspondiente; el tiempo máximo para anotar

una imagen fue de 24 minutos. Fue a partir de esta clasificación que se hizo el muestreo aleatorio estratificado de las 400 imágenes para el experimento del uso de SAM como herramienta de preanotación; el tiempo necesario para anotar estas imágenes fue de 1888 minutos (31.47 horas). Esta estratificación busca evitar que el experimento esté dominado por imágenes “fáciles” de anotar, garantizando que se evalúe el comportamiento de SAM tanto en escenas simples como en contextos de alta complejidad geométrica.




Figura 4.2: Variancia y distribución del tiempo de anotación manual del conjunto experimental, indicándose la estratificación intercuartiles del *ground truth*.

2.1. Análisis exploratorio de los metadatos

Antes de analizar los resultados de preanotación, es necesario caracterizar brevemente las variables categóricas asociadas al muestreo de 400 imágenes, con el fin de evaluar su variabilidad y posible influencia en el rendimiento de SAM. En la Tabla 4.1 posterior se describen las cinco variables categóricas binarias recopiladas manualmente:

Tabla 4.1: Frecuencias de las variables binarias sobre el muestreo de 400 imágenes del conjunto de *ground truth*.

Variable	Si	% Si	No	% No
Seco	318	79.50	82	20.50
Noche	73	18.25	327	81.75
Humanos	85	21.25	315	78.75
Sombras	200	50.00	200	50.00
Anomalía en la acera	219	54.75	181	45.25

tyuyjhPor otro lado, también detallamos las frecuencias de las variables multiclase que nos hablan del tipo de perspectiva - *view*- y la resolución de las imágenes (ver Tabla 4.2). Los resultados observados nos indican que existiría una distribución equilibrada entre los grupos de imágenes con la excepción parcial de la resolución más frecuente de 2992x3020 en la que las imágenes tomadas con perspectiva general y ángulo superior a los 45° respecto al suelo son mi-




Figura 4.3: Variancia y distribución del tiempo de posprocesamiento manual del conjunto experimental, indicándose la estratificación intercuartiles del *ground truth*. Se puede apreciar una mejora del tiempo, en comparación la Figura 4.2.

noritarias. Este desequilibrio no compromete el análisis ni tampoco el posterior entrenamiento, dado que las imágenes con vista superior extrema constituirían el caso de uso real, donde la captura pedestre habitual se realiza con inclinaciones inferiores a 45° ya que el foco de interés es, precisamente, la acera.

Tabla 4.2: Frecuencias de las variables multiclase sobre el muestreo de 400 imágenes del conjunto de *ground truth*.

Vista	general inf 45	general sup 45	primer inf 45
Dimensiones recortadas			
1080x544	0 (0.0 %)	0 (0.0 %)	1 (100.0 %)
1280x544	7 (35.0 %)	8 (40.0 %)	5 (25.0 %)
2992x3020	87 (40.5 %)	40 (18.6 %)	88 (40.9 %)
4000x2259	12 (35.3 %)	14 (41.2 %)	8 (23.5 %)
720x816	0 (0.0 %)	3 (75.0 %)	1 (25.0 %)
720x967	39 (31.0 %)	41 (32.5 %)	46 (36.5 %)

Por otro lado, aunque variables como la iluminación o la humedad presentan fluctuaciones, no se pretende evaluar su impacto en el rendimiento del modelo, sino analizar la transferencia de aprendizaje y la utilidad del BIAA para mejorar la segmentación del dominio peatonal. Así, no se consideran como sesgos a corregir en esta fase.

2.2. Efecto de la preanotación

El tiempo necesario de inferencia de SAM para la predicción de las máscaras del muestreo de 400 imágenes fue de 368 segundos (6 minutos) y con un promedio de 0.92 segundos por imagen. En el contexto de este experimento no constituye un factor limitante del flujo de trabajo, puesto que su impacto temporal es marginal frente al tiempo invertido en revisión manual.

En cambio, el tiempo requerido para realizar la tarea de posprocesamiento manual fue de 1624 minutos (27 horas), es decir, una mejora en aproximadamente cuatro horas y media

(13.98 %) en relación a la anotación manual de las mismas imágenes. El tiempo medio requerido para realizar la tarea de posprocesamiento por cada imagen fue de 4.06 minutos. En cambio, en el 47.25 % de las imágenes no se observó ninguna variación del tiempo preciso y, además, la mejora no se observa que impactase de forma uniforme, como puede comprobarse en la Tabla 4.3:

Tabla 4.3: Comparación del número de imágenes que vieron mejorado o empeorado el tiempo (minutos) preciso de su anotación manual a su posprocesamiento, dejando de lado las imágenes donde el tiempo de ambas tareas fue el mismo, en relación a su estrato intercuartil.

Estrato	Mejor	Peor	Diferencia media	Prop. diferencia (%)
Q1	13	19	0.083	5.494
Q2	48	21	-0.259	-7.444
Q3	42	1	-0.944	-17.467
Q4	67	0	-2.000	-19.423

En el transcurso del experimento se recopiló también el número de máscaras que se eliminaron o modificaron², además de las añadidas (ver Figura 4.4):




Figura 4.4: Frecuencias de las máscaras anotadas manualmente, las predicciones de SAM y de las que requirieron su eliminación, edición o adición. El relativamente reducido número de máscaras editadas responde a que se observó que resultaba más eficiente eliminar y crear nuevas máscaras antes que editar máscaras que resultaban subóptimas, ya por ser una subsegmentación del objeto en cuestión o bien por que abarcaban diversos objetos y requería, por lo tanto, editar además de crear una nueva adicional.

Por último, se observa (en la Tabla 4.4) como son las imágenes con perspectiva general las que concentran el grueso de las mejoras entre el tiempo requerido para su anotación manual y su posprocesamiento.

²Esta medición resulta relevante pues, como ha observado A. Sarkis, la edición o corrección de una máscara resulta más costosa en tiempo que no la creación de una nueva (Sarkis 2024, pág. 248).

Tabla 4.4: Comparación del número de imágenes que vieron mejorado o empeorado el tiempo preciso (en minutos) de su anotación manual a su posprocesamiento, dejando de lado las imágenes donde el tiempo de ambas tareas fue el mismo en relación a su perspectiva.

Perspectiva	Mejor	Peor	Diferencia media	Prop. diferencia (%)
General inf. 45	66	16	-0.752	-8.887
General sup. 45	58	5	-1.085	-12.644
Primer inf. 45	46	20	-0.268	-4.640

Es relevante resaltar que son precisamente estas imágenes las que, probablemente, aporten también más riqueza semántica al modelo pues incorporan en una misma escena muchas instancias de clases distintas facilitando que el modelo generalice patrones útiles que, en última instancia, le permiten obtener un modelo más robusto y generalizable. Por lo tanto, resulta estratégico que SAM sí facilite la tarea de anotación en este tipo de imágenes también más costosas.

3. Entrenamiento con datos del BIAA

A partir de los resultados obtenidos en los apartados anteriores, se procedió a ajustar el modelo DeepLabV3 preentrenado con Cityscapes utilizando exclusivamente el conjunto anotado del BIAA. El objetivo de este experimento no es obtener un modelo óptimo, sino evaluar si un volumen reducido de datos locales es capaz de corregir los sesgos derivados del entrenamiento original, especialmente la tendencia a reinterpretar el pavimento peatonal como calzada. Con este fin, se entrenaron varias configuraciones del modelo, analizando su rendimiento mediante métricas cuantitativas y una evaluación cualitativa de los errores en escenas reales.

3.1. Resultados cuantitativos (métricas)

Tabla 4.5: Comparación de las métricas de los cuatro entrenamientos de la arquitectura DeepLabV3 preentrenada con Cityscapes.

Designación	epoch	mIoU	Pérdida (val)
Optim. Adam (52 epochs)	45	0.595793	0.602761
Optim. Adam (47 epochs)	27	0.544313	0.528324
Optim. AdamW (31 epochs)	30	0.537283	0.620337
Optim. AdamW (44 epochs)	25	0.536085	0.570640

Los resultados de los cuatro experimentos se resumen en la Tabla 4.5. El modelo con mejor desempeño corresponde al entrenamiento con optimizador Adam durante 52 epochs, alcanzando un mIoU de 0.5958. En comparación, los modelos entrenados con AdamW muestran un rendimiento más estable, aunque con valores máximos de mIoU ligeramente inferiores (0.536–0.537).

Esto sugiere una mayor capacidad de adaptación del optimizador Adam al conjunto de datos reducido y específico del BIAA.

En su conjunto los resultados relativos a la pérdida entre el subconjunto de validación muestran, en los tres casos subóptimos (ver Anexo D, Figuras D.2, D.3 y D.4), que el entrenamiento se demostró inestable, hecho coherente al realizarlo con un conjunto reducido de datos específicos; a su vez, se observa una tendencia a la estabilidad en el caso más óptimo (ver Anexo D, Figura D.1). No obstante, el rango de valores obtenidos indica que el ajuste no sería global ni homogéneo entre clases, lo que refuerza la importancia de analizar el IoU por clase sobre el conjunto de test, presentado a continuación en la Tabla 4.6:

Tabla 4.6: Comparación de las métricas mIoU e IoU por clase de los cuatro entrenamientos de la arquitectura DeepLabV3 preentrenada con Cityscapes sobre el conjunto de test.

Experimento	mIoU	A. modular	A. asfáltica	Calzada	Bordillo	Drenaje	Cuneta	T. registro	Alcorque	Vegetación	Mobiliario
Optim. Adam (52 epochs)	0.56332	0.92966	0.00511	0.75297	0.51800	0.73303	0.56031	0.46956	0.56460	0.55032	0.54968
Optim. Adam (47 epochs)	0.52671	0.90854	0.00842	0.70860	0.43564	0.77121	0.44181	0.39427	0.58175	0.61101	0.40589
Optim. AdamW (31 epochs)	0.53906	0.92002	0.00000	0.77067	0.43168	0.80351	0.45615	0.51577	0.56236	0.49700	0.43339
Optim. AdamW (44 epochs)	0.50415	0.87721	0.00660	0.67405	0.45895	0.70013	0.42603	0.45045	0.41365	0.55792	0.47645

En primer lugar, constatamos que el mIoU no empeora tras el ajuste del modelo con los datos del BIAA, sino que se mantiene en un rango similar e incluso mejora en el caso del entrenamiento AdamW de 31 épocas. Este comportamiento indica que el modelo no sobreajusta ni pierde capacidad general pese al tamaño reducido del conjunto, lo que refuerza la utilidad del *fine-tuning* con datos específicos del dominio.

De forma esperada, todas las configuraciones muestran valores muy elevados relativos a la acera modular pues también esta es la instancia más frecuente (ver Anexo B, Figura B.4) y también la que ocupa mayor área en todas las máscaras que han sido ingeridas por el entrenamiento (ver Anexo B, Figura B.6). Esto sugiere que el modelo incorpora con facilidad patrones del pavimento modular, especialmente cuando son regulares y repetitivos.

En contraste, la clase rara correspondiente a la acera asfáltica es también la que obtiene los peores resultados en los cuatro experimentos. De forma llamativa, el modelo con mejor mIoU (Adam de 52 épocas) es el segundo peor en clasificar este tipo de pavimento. En cambio, los dos modelos que logran mejor IoU de esta clase - aunque la diferencia es marginal- son los que también obtienen significativamente peores indicadores IoU por la clase correspondiente a la calzada, cuestión que nos sugiere que DeepLabV3 no logra aprender rasgos diferenciadores robustos entre acera asfáltica y calzada bajo el contexto de Barcelona y su área metropolitana.

Esto nos induce a observar que la similitud visual entre pavimento asfáltico peatonal y el de la calzada que, como ya observamos en la anterior Figura 2.2, presenta la peculiaridad de ser un dominio que se representa con una función continua de valores. Por ello, entendemos que induce a su confusión sistemática, impidiendo también el reducido volumen de ejemplos de acera asfáltica en el *ground truth* del BIAA que el modelo entrenado incorpore reglas de separación basadas en forma, geometría o textura.

Así, el *fine-tuning* con el BIAA corrige parcialmente sesgos de Cityscapes, pero solo cuando las clases presentan suficiente frecuencia y variabilidad. En consecuencia, la mejora del modelo no dependería únicamente del número total de imágenes anotadas, sino de la proporción de ejemplos representativos de clases difíciles de distinguir visualmente.

3.2. Resultados cualitativos de las predicciones

El subconjunto de test está constituido por 76 imágenes también seleccionadas aleatoriamente del conjunto de 507 imágenes de la *ground truth* del BIAA. Respondiendo a la necesidad de poder hacer el necesario análisis cualitativo y de los errores, solamente se analizará un muestreo de 6 imágenes seleccionadas para representar los patrones más relevantes y representativos (ver miniatura en Figura 4.5), presentando la imagen original, la predicción del modelo original preentrenado con el dataset Cityscapes y la predicción de las máscaras por nuestro modelo ajustado, acompañándola con su descripción y análisis, además de la valoración de las tendencias generales que pueden apreciarse.

En primer lugar, se aprecia que la ausencia de una clase específica para fachadas, muros y superficies verticales construidas conduce a un mal resultado cualitativo y un elevado número de falsos positivos, pues este tipo de objetos fueron incluidos sistemáticamente durante el proceso de anotación en la clase *ignore* (255). Resulta claro que su inclusión será imperativa en futuras iteraciones del proyecto.

Otro fenómeno de interés que se observa de forma generalizada es la tendencia a clasificar como alcorques los baches en la acera (ver Anexo D, Figura D.5). En esta primera iteración del proyecto se optó por no incluir una clase específica para las anomalías funcionales en la acera modular o en los bordillos, incluyéndolas en la clase de las aceras modulares (*sidewalk_tiles*) y bordillos (*curb_edge*) respectivamente. El modelo, en cambio, asocia este patrón con los alcorques cuando detecta una ausencia de pavimento en un contexto de acera, al margen de encontrarse también arbolado o vegetación. Este es un patrón que se corresponde con el hecho que existe el caso real de los alcorques provisionalmente sin arbolado o vacíos, fruto de la necesidad de su retirada por parte del servicio municipal competente, generalmente, al enfermar o morir la planta (ver Anexo D, Figura D.6).

Otra tendencia observada es que las condiciones diurnas o nocturnas de la escena afectan de forma limitada al rendimiento del modelo, sugiriendo esto, con la debida cautela al tratarse de un *dataset* de tamaño reducido, que la proporción de escenas nocturnas del 20 % en el conjunto de entrenamiento (ver el apartado 2.1, especialmente la Tabla 4.2)³ permitiría obtener resultados

³Aunque hemos observado que el efecto de la aleatoriedad para la creación de los tres subconjuntos ha conducido a subrepresentar las escenas nocturnas a solamente el 13 % en el subconjunto de test y, por lo tanto, inferimos que aumentó su peso en los otros dos subconjuntos.




Figura 4.5: Miniatura de las 6 imágenes seleccionadas para el análisis cualitativo. El análisis detallado de cada muestra puede consultarse en el Anexo D.

robustos en estas condiciones.

Finalmente, otra tendencia reseñable es la asociación que hace el modelo entre vehículos y personas - que cuentan todas con máscaras *ignore* en la *ground truth*- que actúan como oclusiones de la acera modular y la calzada. De esta manera, se ha podido comprobar la tendencia a que el modelo tienda a ignorar las figuras humanas al realizar la clasificación entre ambas clases (ver ejemplo en el Anexo D, D.5). En el caso de las motocicletas, la tendencia sería clasificar la región ocultada como acera modular, haciéndolo solamente como calzada en el caso de no contar con suficiente contexto, como serían regiones definidas de bordillo y cuneta (ver ejemplo en el Anexo D, Figura D.9). En cambio, en el caso de los coches, las observaciones sobre el conjunto de test nos sugieren a que lo asocia sistemáticamente con la calzada, siendo posiblemente éste un sesgo originado por el modelo preentrenado con Cityscapes.

Todas estas limitaciones detectadas nos sugieren que el modelo aún depende en exceso de señales locales y de patrones heredados del preentrenamiento con Cityscapes, especialmente en clases donde la distinción funcional no puede resolverse únicamente a partir de textura o color. La incapacidad para discriminar de forma consistente entre acera asfáltica y calzada, la confusión entre baches y alcorques o la dificultad para fijar con precisión la geometría del bordillo evidencian que el modelo no está captando todavía la estructura espacial del dominio peatonal. Sin lugar a dudas, un *dataset* de mayor tamaño y que tenga también siempre en consideración la variabilidad obtendría un rendimiento muy superior, tanto en las métricas como también cualitativamente.

En conjunto, estos resultados cualitativos apuntan a que futuras iteraciones deberán reforzar la representación de clases críticas (bordillo, acera asfáltica, cuneta), incorporar una clase específica para fachadas y elementos verticales y ampliar la diversidad geométrica del *dataset*, especialmente en contextos donde la textura no es discriminativa y el modelo necesita apoyarse en relaciones espaciales entre objetos.

De este modo, si bien estos resultados no permiten aún un uso operativo directo del modelo entrenado, en cambio sí apuntan a que el BIAA no solamente podría corregir las limitaciones del preentrenamiento vehicular, sino también constituir la base para modelos que integren semántica funcional y aporten valor real a las tareas de inspección y mantenimiento del espacio público.

Capítulo 5

Conclusiones

El presente trabajo se ha centrado en el estudio del espacio público urbano desde la perspectiva de la visión por computador, abordando de manera específica la problemática de la segmentación y caracterización del pavimento peatonal. A diferencia de otros enfoques habituales en el ámbito de la visión urbana, tradicionalmente orientados al dominio vehicular, este proyecto parte de la premisa de que las aceras y los entornos peatonales constituyen un dominio con entidad propia, cuyas características geométricas, funcionales y semánticas no quedan adecuadamente representadas en los conjuntos de datos y modelos de referencia más utilizados, como sería el caso de Cityscapes.

En este contexto, el principal objetivo del trabajo no ha sido la obtención de un modelo de segmentación óptimo en términos de métricas cuantitativas, sino la construcción y validación de un conjunto de datos específico que permita abordar el problema desde una perspectiva adecuada. El desarrollo del Banco de Imágenes de Anotaciones de Aceras (BIAA) responde a esta necesidad, proporcionando un conjunto de datos anotado con criterios funcionales y alineado con las exigencias reales del mantenimiento y la monitorización del espacio público.

Los resultados obtenidos a lo largo del trabajo ponen de manifiesto, por un lado, las limitaciones inherentes a la transferencia directa de modelos preentrenados en dominios vehiculares, como Cityscapes, hacia escenarios peatonales. Estas limitaciones se reflejan tanto en las métricas cuantitativas como en el análisis cualitativo de las predicciones, evidenciando confusiones sistemáticas entre clases funcionalmente distintas y una dependencia excesiva de señales locales como la textura o el color. Por otro lado, los experimentos realizados muestran que, incluso con un conjunto de datos de tamaño reducido, la introducción de un *dataset* específico y con una variabilidad adecuada permite desplazar el comportamiento del modelo hacia patrones más coherentes con la semántica del dominio peatonal.

En este sentido, el análisis cualitativo ha desempeñado un papel central en la interpretación de los resultados, permitiendo identificar patrones de error recurrentes y comprender las causas

subyacentes de las confusiones observadas. Este enfoque ha resultado especialmente relevante en un contexto en el que las métricas globales, como el mIoU, pueden no capturar por sí solas la adecuación funcional de las predicciones ni su potencial utilidad en aplicaciones reales de mantenimiento urbano.

De forma complementaria, el trabajo ha permitido reflexionar sobre el proceso de anotación como una fase crítica del desarrollo de sistemas de visión por computador aplicados al entorno urbano. La evaluación del uso de herramientas de preanotación automática, como SAM, ha puesto de relieve tanto su potencial para reducir el esfuerzo manual como sus limitaciones cuando no se dispone de un contexto semántico suficientemente definido. Estas observaciones refuerzan la idea de que la calidad y el diseño del *dataset* constituyen un factor determinante en el rendimiento y la interpretabilidad de los modelos entrenados.

En conjunto, este trabajo pone de manifiesto que la construcción de recursos de datos específicos y cuidadosamente anotados es un paso imprescindible para avanzar hacia sistemas de monitorización inteligente del espacio público peatonal en Barcelona, caracterizado por tipologías de pavimento, criterios de mantenimiento y prácticas de gestión específicas. Más allá de los resultados obtenidos en esta primera iteración, el valor principal del proyecto reside en haber establecido una base metodológica y conceptual sólida sobre la que desarrollar futuras investigaciones y aplicaciones, abriendo así una línea de trabajo orientada a la integración de la visión por computador en tareas reales de inspección y mantenimiento de infraestructuras urbanas.

1. Límites y perspectivas de futuro

El alcance de este trabajo ha estado deliberadamente acotado a la construcción y validación de un conjunto de datos específico para la segmentación funcional del pavimento peatonal, así como a la evaluación exploratoria del comportamiento de modelos de visión por computador en este dominio. En consecuencia, han quedado fuera del ámbito de estudio aspectos como la detección directa de incidencias de mantenimiento, la explotación sistemática de información geográfica y contextual o la plena escalabilidad operativa del banco de datos. No obstante, estos límites no deben interpretarse como carencias del trabajo, sino como el resultado de un diseño progresivo que permite identificar con claridad las líneas de desarrollo más relevantes para futuras iteraciones del proyecto.

Una primera línea de trabajo futura consiste en el enriquecimiento del esquema de anotación con el objetivo de abordar la segmentación de incidencias de mantenimiento en pavimentos modulares. Mientras que en esta primera fase las anomalías funcionales se han integrado dentro de las clases correspondientes al pavimento y a los bordillos, futuras ampliaciones del BIAA

deberían contemplar la definición explícita de este tipo de incidencias, tales como deformaciones, baches, pérdida de piezas o discontinuidades del firme. Este paso implicaría no solo la incorporación de nuevas clases, sino también una reflexión metodológica sobre los criterios de anotación y la distinción entre elementos estructurales y estados de degradación, sentando las bases para aplicaciones orientadas al mantenimiento predictivo.

Una segunda línea de desarrollo relevante se relaciona con la integración sistemática del análisis de datos geoespaciales y de los metadatos asociados a las imágenes. La disponibilidad de información como las coordenadas geográficas y la marca temporal ya permiten profundizar en el estudio de factores contextuales que influyen en el rendimiento de los modelos, como las condiciones diurnas o nocturnas, la iluminación artificial, las sombras proyectadas o la orientación de las escenas. Asimismo, el análisis espacial de los datos podría facilitar la identificación de patrones territoriales en la degradación del pavimento, aportando una dimensión analítica complementaria a la segmentación puramente visual además de guiar posteriores ampliaciones del número de instancias del BIAA o el uso de dispositivos más especializados para su captura.

En paralelo, resulta pertinente considerar la exploración de herramientas y metodologías basadas en información tridimensional. El análisis en dos dimensiones presenta limitaciones evidentes a la hora de capturar desniveles, deformaciones volumétricas o irregularidades sutiles del pavimento, especialmente relevantes desde el punto de vista de la accesibilidad y la seguridad peatonal. En este sentido, el uso de técnicas como la fotogrametría, la reconstrucción de superficies o el análisis de nubes de puntos podría complementar los enfoques actuales, permitiendo una caracterización más precisa de determinadas anomalías y abriendo nuevas posibilidades para la monitorización del estado del espacio público.

Finalmente, una línea de trabajo transversal a las anteriores consiste en la consolidación del BIAA como un recurso escalable y reutilizable. La ampliación progresiva del conjunto de datos, tanto en volumen como en diversidad de contextos urbanos, permitiría entrenar modelos más robustos y especializados, así como facilitar su adaptación a distintos escenarios de aplicación. En este sentido, el BIAA podría evolucionar desde un banco de imágenes inicial hacia una infraestructura de datos que soporte segmentaciones cada vez más específicas y alineadas con necesidades concretas de gestión urbana, siendo siempre compatible con la coherencia metodológica y la trazabilidad del proceso de anotación.

De forma complementaria, una línea exploratoria de trabajo futuro podría considerar el uso de modelos generativos aplicados a tareas de segmentación, como las Redes Generativas Adversarias (GANs) o arquitecturas basadas en UNet. Este tipo de enfoques permitiría investigar la relación entre la generación condicionada de máscaras y la segmentación supervisada clásica, así como evaluar su comportamiento en un contexto de datos específicos como el BIAA. La disponibilidad de métricas ya empleadas en este trabajo, como la IoU, facilitaría una comparación

sistemática de resultados y una valoración objetiva de su potencial aplicabilidad.

En conjunto, estas líneas de trabajo apuntan a una evolución natural del proyecto, en la que la construcción de un *dataset* específico constituye el punto de partida para el desarrollo de sistemas más complejos de análisis y monitorización del espacio público peatonal. Lejos de cerrar el problema, el presente trabajo establece las bases necesarias para avanzar de forma progresiva hacia soluciones más completas, integrando nuevas dimensiones de análisis y reforzando la conexión entre la visión computacional y las tareas reales de mantenimiento de las infraestructuras urbanas.

Bibliografía

- Ahmadi, Mohsen et al. (2025). “Application of segment anything model for civil infrastructure defect assessment”. En: *Innovative Infrastructure Solutions* 10. DOI: [10.36680/j.itcon.2024.035](https://doi.org/10.36680/j.itcon.2024.035).
- Ajuntament de Barcelona (2021). *Cuidem Barcelona, el plan de mantenimiento integral del espacio público de la ciudad*. URL: <https://ajuntament.barcelona.cat/ecologiaurbana/es/servicios/la-ciudad-funciona/mantenimiento-del-espacio-publico/gestion-de-limpieza-y-residuos/cuidem-barcelona> (visitado 06-10-2025).
- (2023). *Pla Endreça Barcelona*. Barcelona: Ajuntament de Barcelona. URL: https://bcnroc.ajuntament.barcelona.cat/jspui/bitstream/11703/132752/1/AJUNTAMENT%20BCN%20PLA%20ENDRECA_CC.PDF.
- (2024). *Enquesta de Serveis Municipals 2024. Del 29 de gener al 29 d’abril de 2024*. Barcelona: Ajuntament de Barcelona. URL: https://ajuntament.barcelona.cat/premsa/wp-content/uploads/2024/09/r24003_Serveis_Municipals_Informe_Resum_v1_0.pdf.
- (2025). *Barcelona a la Butxaca*. URL: <https://ajuntament.barcelona.cat/apps/es/barcelona-la-butxaca> (visitado 30-10-2025).
- Almazroey, Alaa Atallah, Salma Kammoun Jarraya y Reem Alnanih (2025). “SAM for road object segmentation: Promising but challenging”. En: *Journal of Imaging* 11. DOI: [10.3390/jimaging11060189](https://doi.org/10.3390/jimaging11060189).
- Bashiri, Samaneh, Luca Raffini y Elvezia Maria Cepolina (2025). “Criteria for establishing priorities in sidewalk maintenance when using multi-criteria analysis in order to achieve inclusive mobility”. En: *Urban Science* 9. DOI: [10.3390/urbansci9020047](https://doi.org/10.3390/urbansci9020047).
- BielGlasses (2024). *Barcelona Streets Dataset*. <https://universe.roboflow.com/bielglasses/barcelona-streets>. Open Source Dataset. visited on 2025-12-23. URL: <https://universe.roboflow.com/bielglasses/barcelona-streets>.
- Chen, Yi-Hsin et al. (2017). “No more discrimination: Cross city adaptation of road scene segmenters”. En: *2017 IEEE International Conference on Computer Vision (ICCV)*, págs. 2011-2020. DOI: [10.1109/ICCV.2017.220](https://doi.org/10.1109/ICCV.2017.220).

- Chen, Liang-Chieh et al. (2018). “DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs”. En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 40.4, págs. 834-848. DOI: [10.1109/TPAMI.2017.2699184](https://doi.org/10.1109/TPAMI.2017.2699184).
- Chen, Yi et al. (2025). “AoP-SAM: Automation of prompts for efficient segmentation”. En: *AAAI’25/IAAI’25/EAAI’25: Proceedings of the Thirty-Ninth AAAI Conference on Artificial Intelligence and Thirty-Seventh Conference on Innovative Applications of Artificial Intelligence and Fifteenth Symposium on Educational Advances in Artificial Intelligence*, págs. 2284-2292. DOI: [10.1609/aaai.v39i2.32228](https://doi.org/10.1609/aaai.v39i2.32228).
- Cheng, Bowen et al. (2022). “Masked-attention Mask Transformer for Universal Image Segmentation”. En: *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 1280-1289. DOI: [10.1109/CVPR52688.2022.00135](https://doi.org/10.1109/CVPR52688.2022.00135).
- Choi, Min Je, Dong Gyun Ku y Seung Jae Lee (2022). “Integrated YOLO and CNN algorithms for evaluating degree of walkway breakage”. En: *KSCE Journal of Civil Engineering* 26, págs. 3570-3577. DOI: [10.1007/s12205-022-1017-1](https://doi.org/10.1007/s12205-022-1017-1).
- Corazza, Maria Vittoria, Paola Di Mascio y Paola Moretti (2017). “Management of sidewalk maintenance to improve walking comfort for senior citizens”. En: *WIT Transactions on the Built Environment* 176, págs. 195-207. DOI: [10.2495/UT170171](https://doi.org/10.2495/UT170171).
- Cordts, Marius et al. (2016). “The Cityscapes dataset for Semantic urban scene understanding”. En: *2016 IEEE Conference in Computer Vision and Pattern Recognition*. Washington DC: IEEE Computer Society, págs. 3213-3223. DOI: [10.1109/CVPR.2016.350](https://doi.org/10.1109/CVPR.2016.350).
- Damaceno, R.J.P. et al. (2024). “SideSeeing: A multimodal dataset and collection of tools for sidewalk assessment”. En: *arXiv* 2407.06464. URL: <https://arxiv.org/pdf/2407.06464>.
- De Deijn, Ricardo y Rajeev Bukralia (2024). “Image classification for snow detection to improve pedestrian safety”. En: *Proceedings of the Nineteenth Midwest Association for Information Systems Conference, Peoria, Illinois, May 16-17, 2024*. Atlanta, GA: Association for Information Systems. DOI: [10.48550/arXiv.2407.00818](https://doi.org/10.48550/arXiv.2407.00818).
- Denton, Emily et al. (2021). “On the genealogy of machine learning datasets: A critical history of ImageNet”. En: *Big Data and Society* 8.2, págs. 1-14. DOI: [10.1177/20539517211035955](https://doi.org/10.1177/20539517211035955).
- Facebook Research (2021). *Masked-attention Mask Transformer for Universal Image Segmentation*. URL: <https://huggingface.co/facebook/mask2former-swin-small-cityscapes-semantic> (visitado 14-12-2025).
- Fan, Kanxu et al. (2025). “Research on medical image segmentation based on SAM and its future prospects”. En: *Bioengineering* 12. DOI: [10.3390/bioengineering12060608](https://doi.org/10.3390/bioengineering12060608).
- Fang, Gongfan (2022). *DeepLabv3Plus-Pytorch*. URL: <https://github.com/VainF/DeepLabV3Plus-Pytorch> (visitado 14-12-2025).

- Fonseca, Fernando, Alexandra Rodrigues y Hugo Silva (2025). “Pedestrian perceptions of sidewalk paving attributes: Insights from a pilot study in Braga”. En: *Infrastructures* 10. DOI: [10.3390/infrastructures10040079](https://doi.org/10.3390/infrastructures10040079).
- Franchi, Gianni et al. (2021). “Robust semantic segmentation with Superpixel-Mix”. En: *arXiv* 2108.00968. DOI: [10.48550/arXiv.2108.00968](https://doi.org/10.48550/arXiv.2108.00968).
- Gemminis (2025). *Inventarios mediante Inteligencia Artificial*. URL: <https://gemminis.io/> (visitado 06-10-2025).
- Géron, Aurélien (2023). *Aprende Machine learning con Scikit-Learn, Keras y TensorFlow. Conceptos, herramientas y técnicas para conseguir sistemas inteligentes*. Madrid: Ediciones Anaya.
- Gibson, Peyton Jane y Wesley E. Marshall (2022). “Disparate approaches to maintaining roads and sidewalks: an interview study in 16 U.S. cities”. En: *Transportation Research Record* 2676.9. DOI: [10.1177/03611981221087239](https://doi.org/10.1177/03611981221087239).
- Gupta, Agrim, Piotr Dollár y Ross Girschik (2019). “LVIS: A dataset for large vocabulary instance segmentation”. En: *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 5356-5364. DOI: [10.1109/CVPR.2019.00550](https://doi.org/10.1109/CVPR.2019.00550).
- He, Kaiming et al. (2020). “Mask R-CNN”. En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.2, págs. 386-397. DOI: [10.1109/TPAMI.2018.2844175](https://doi.org/10.1109/TPAMI.2018.2844175).
- Hosseini, Maryam, Fabio Miranda et al. (2022). “CitySurfaces: City-scale semantic segmentation of sidewalk materials”. En: *Sustainable Cities and Society* 79. DOI: [10.1016/j.scs.2021.103630](https://doi.org/10.1016/j.scs.2021.103630).
- Hosseini, Maryam, Andres Sevtsuk et al. (2023). “Mapping the walk: A scalable computer vision approach for generating sidewalk network datasets from aerial imagery”. En: *Computers, Environment and Urban Systems* 101. DOI: [10.1016/j.compenvurbsys.2023.101950](https://doi.org/10.1016/j.compenvurbsys.2023.101950).
- Ibn Sultan, Rafi et al. (2024). “GeoSAM: Fine-tuning SAM with multi-modal prompts for mobility infrastructure segmentation”. En: *arXiv* 2311.11319. DOI: [10.48550/arXiv.2311.11319](https://doi.org/10.48550/arXiv.2311.11319). URL: <https://arxiv.org/pdf/2311.11319v3>.
- Khosla, Aditya et al. (2012). “Undoing the damage of dataset bias”. En: *Computer Vision - ECCV 2012: 12th European Conference on Computer Vision, Florence, Italy, October 7-13, 2012. Proceedings, Part I*. Berlín: Springer, págs. 158-171. DOI: [10.1007/978-3-642-33718-5_12](https://doi.org/10.1007/978-3-642-33718-5_12).
- Kirillov, Alexander et al. (2023). “Segment Anything”. En: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. Versión ampliada disponible como preprint en arXiv:2304.02643, págs. 4015-4026. DOI: [10.48550/arXiv.2304.02643](https://doi.org/10.48550/arXiv.2304.02643). URL: <https://arxiv.org/abs/2304.02643>.

- Koushik (2025). *DeepLabV3 ResNet-50 - Cityscapes (Numpy Format)*. URL: <https://huggingface.co/Koushim/deeplabv3-resnet50-cityscapes> (visitado 01-12-2025).
- Labelme (2025). *Create your image dataset for vision AI*. URL: <https://labelme.io/> (visitado 08-12-2025).
- Laohaprapanon, Suriyan, Kimberly Ortleb y Gurav Sood (2018). “Street Sense: Learning from Google Street View”. En: *arXiv* 1807.06075v1. DOI: [10.48550/arXiv.1807.06075](https://doi.org/10.48550/arXiv.1807.06075).
- Li, Chu et al. (2024). “LabelAid: Just-in-time AI interventions for improving human labeling quality and domain knowledge in crowdsourcing systems”. En: *CHI’24: Proceedings of the 2024 CHI Conference on human factors in computing systems*. DOI: [10.1145/3613904.3642089](https://doi.org/10.1145/3613904.3642089).
- Lin, Tsung-Yi et al. (2015). “Microsoft COCO: Common objects in context”. En: *arXiv* 1405.0312v3. DOI: [10.48550/arXiv.1405.0312](https://doi.org/10.48550/arXiv.1405.0312). URL: <https://arxiv.org/pdf/1405.0312>.
- Mentis, Alexios-Fotios y Jannis S. Papadopoulos (2021). “Near-collapse buildings and unsafe sidewalks as neglected urban and public health issue: A qualitative study”. En: *Urban Science* 5. DOI: [10.3390/urbansci5020047](https://doi.org/10.3390/urbansci5020047).
- MiTMyAU (2021). *Guía de accesibilidad en los espacios públicos urbanizados V.1.0*. Centro virtual de publicaciones del Ministerio de Transportes, Movilidad y Agenda Urbana. URL: https://cdn.mitma.gob.es/portal-web-drupal/estudios_y_publicaciones/guia_accesibilidad.pdf.
- Neuhold, Gerhard et al. (2017). “The Mapillary Vistas dataset for Semantic understanding of street scenes”. En: *2017 IEEE International Conference in Computer Vision (ICCV), Venice, Italy*. Washington DC: IEEE Computer Society, págs. 5000-5009. DOI: [10.1109/ICCV.2017.534](https://doi.org/10.1109/ICCV.2017.534).
- Paullada, Amandalynne et al. (2021). “Data and its (dis)contents: A survey of dataset development and use in machine learning research”. En: *Patterns* 2.11. DOI: [10.1016/j.patter.2021.100336](https://doi.org/10.1016/j.patter.2021.100336).
- Porfido, Enrico et al. (2025). “Assessing older adults’s walkability in the surroundings of Primary Care Centers: A three-case study from Barcelona”. En: *Sustainability* 17. DOI: [10.3390/su17156658](https://doi.org/10.3390/su17156658).
- Ramírez Jávega, Joan Manel (2025a). *BIAA v100 GT*. https://universe.roboflow.com/biaa/biaa_v100_gt. Open Source Dataset. visited on 2025-12-26. URL: https://universe.roboflow.com/biaa/biaa_v100_gt.
- (2025b). *BIAA v100 GT repository*. https://github.com/ramirezjmsrike/BIAA_TFM/tree/main. GitHub repository. visited on 2025-12-26. URL: https://github.com/ramirezjmsrike/BIAA_TFM/tree/main.

- Ravi, Nikhila et al. (2024). “SAM 2: Segment Anything in Images and Videos”. En: *arXiv* 2408.00714v4. DOI: [10.48550/arXiv.2408.00714](https://doi.org/10.48550/arXiv.2408.00714). URL: <https://arxiv.org/abs/2408.00714>.
- Saha, Manaswi et al. (2019). “Project Sidewalk: A web-based crowdsourcing tool for collecting sidewalk accessibility data at scale”. En: *CHI’19: Proceedings of the 2019 CHI Conference on human factors in computing systems*. DOI: [10.1145/3290605.3300292](https://doi.org/10.1145/3290605.3300292).
- Sambasivan, Nithya et al. (2021). “Everyone wants to do the model work, not the data work: Data cascades in high-stakes AI”. En: *CHI’21: Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. Yokohama: Association for Computing Machinery. DOI: [10.1145/3411764.344551](https://doi.org/10.1145/3411764.344551).
- Sarkis, Anthony (2024). *Training data for machine learning: Human supervision from annotation to Data science*. Sebastopol, CA: O’Reilly.
- Shihab, Ibne Farabi, Sudesh Ramesh Bhagat y Anuj Sharma (2024). “Precise and robust sidewalk detection: Leveraging Ensemble learning to surpass LLM limitations in urban environments”. En: *arXiv* 2405.14876. DOI: [10.48550/arXiv.2405.14876](https://doi.org/10.48550/arXiv.2405.14876). URL: <https://arxiv.org/pdf/2405.14876>.
- Solocator (2025). *Photos with direction*. URL: <https://solocator.com/> (visitado 08-12-2025).
- Sousa, Nuno, Joao Coutinho-Rodrigues y Eduardo Natividade Jesus (2017). “Sidewalk infrastructure assessment using a multicriteria methodology for maintenance planning”. En: *Journal of Infrastructure Systems* 23.4. DOI: [10.1061/\(ASCE\)IS.1943-555X.0000362](https://doi.org/10.1061/(ASCE)IS.1943-555X.0000362).
- Srivastava, Megha, Tatsunori Hashimoto y Percy Liang (2020). “Robustness to spurious correlations via human annotations”. En: *ICML’20: Proceedings of the 37th International Conference on Machine Learning*. Londres: Association for Computer Machinery, págs. 9109-9119. DOI: [10.48550/arXiv.2007.06661](https://doi.org/10.48550/arXiv.2007.06661).
- Sun, Ke et al. (2019). “High-resolution representations for labeling pixels and regions”. En: *arXiv* 1904.04514. DOI: [10.48550/arXiv.1904.04514](https://doi.org/10.48550/arXiv.1904.04514).
- U.S. Department of Justice (2025). *American with Disabilities Act*. URL: <https://www.ada.gov/> (visitado 31-10-2025).
- Utami, Retno, Carlos Osorio Sandoval y Nicholas Thom (2024). “State-of-the-art review on the integration of BIM with pavement management systems”. En: *Journal of Information Technology in Construction* 29, págs. 810-825. DOI: [10.36680/j.itcon.2024.035](https://doi.org/10.36680/j.itcon.2024.035).
- Valls, Francesc y Álvaro Clua (2023). “Modeling Barcelona sidewalks: A high resolution urban scale assessment of the geometrix attributes of the walkable network”. En: *PLoS ONE* 18. DOI: [10.1371/journal.pone.0284630](https://doi.org/10.1371/journal.pone.0284630).

- Wang, Jingdong et al. (2021). *High-resolution networks and Segmentation Transformer for Semantic Segmentation*. URL: <https://github.com/HRNet/HRNet-Semantic-Segmentation> (visitado 14-12-2025).
- Wang, Tong et al. (2025). “Autonomus UAV-based system for scalable tactile inspection”. En: *Drones* 9.8, págs. 554-583. DOI: [10.3390/drones9080554](https://doi.org/10.3390/drones9080554).
- Wang, Xin et al. (2025). “Comprehensive review of segment anything model across multiple domains”. En: *Digital Signal Processing* 167. DOI: [10.1016/j.dsp.2025.105459](https://doi.org/10.1016/j.dsp.2025.105459).
- Weld, Galen et al. (2019). “Deep Learning for automatically detecting sidewalk accessibility problems using streetscape imagery”. En: *ASSETS’19: Proceedings of the 21st International ACM SIGACCESS Conference on computers and accessibility*, págs. 196-209. DOI: [10.1145/3308561.335379](https://doi.org/10.1145/3308561.335379).
- Xiao, Kai et al. (2020). “Noise or signal: The role of image backgrounds in object recognition”. En: *arXiv* 2006.09994v1. DOI: [10.48550/arXiv.2006.09994](https://doi.org/10.48550/arXiv.2006.09994). URL: <https://arxiv.org/pdf/2006.09994>.
- Yoon, Ha-Yeong, Jung-Hwa Kim y Jin Woo Jeong (2022). “Classification of the sidewalk condition using Self-supervised transfer learning for wheelchair safety driving”. En: *Sensors* 22.1. DOI: [10.3390/s22010380](https://doi.org/10.3390/s22010380).
- Yu, Fisher et al. (2020). “BDD100K: A diverse driving dataset for heterogeneous multitask learning”. En: *arXiv* 1805.04687v2. DOI: [10.48550/arXiv.1805.04687](https://doi.org/10.48550/arXiv.1805.04687). URL: <https://arxiv.org/pdf/1805.04687>.
- Zhang, Renrui et al. (2023). “Personalize Segment anything Model with one shot”. En: *arXiv* 2305.03048v2. DOI: [10.48550/arXiv.2305.03048](https://doi.org/10.48550/arXiv.2305.03048).
- Zou, Yang et al. (2019). “Unsupervised domain adaptation for semantic segmentation via class-balanced self-training”. En: *ECCV 2018: 12th European Conference on Computer Vision, Munich, Germany. September 8-14 2018*. Berlín: Springer, págs. 297-313. DOI: [10.1007/978-3-030-01219-9_18](https://doi.org/10.1007/978-3-030-01219-9_18).

Anexo A

Cuestionario

El cuestionario original era en catalán, siendo esta la traducción al castellano realizada por el autor. Se puede consultar el cuestionario original publicado en Typeform en este enlace:

<https://c6prju40nkr.typeform.com/to/RKBlukpc>

Pregunta 1: Nombre y apellidos

Rubèn Valldeoriola Domínguez.

Pregunta 2: Titulación superior

Graduado en arquitectura técnica y edificación.

Pregunta 3: Localidad donde se ha desarrollado el grueso de su experiencia profesional
Barcelona.

Pregunta 4: Antigüedad y descripción del lugar de trabajo

19 años en el sector de la construcción, redacción de proyectos, dirección de la ejecución de obras, tanto de edificación como de urbanización. Como liberal autónomo y funcionario.

Pregunta 5: Definición de acera: ¿Qué es, según su opinión, una acera? Solamente se requiere una definición sintética.

Una acera es un ámbito habitualmente público para el paso exclusivo de peatones, diferenciado tanto por materiales, rasantes, cromatismo, elementos urbanos... Incluye todos los elementos urbanos necesarios para el correcto funcionamiento del municipio.

Pregunta 6: ¿Qué es una acera pasante? ¿Se puede circular con un vehículo, del mismo modo que lo puede hacer también en el ámbito de una reserva para una licencia de vado? ¿Forma parte de la acera o de la calzada?

Una acera pasante es un cruce de calzada con prioridad para el peatón, asimilable a un paso de peatones, pero al mismo rasante de la acera, no de la calzada. Puede estar semaforizada o no.

Pregunta 7: ¿Cuál es la diferencia entre una *Zona peatonal*, una *Zona de prioridad invertida* y una *Plataforma única*? ¿Cuáles serían sus diferencias funcionales? ¿En estos tres casos se puede hablar de la existencia de acera y calzada?

Las *zonas peatonales* corresponden al ámbito exclusivo para peatones, aunque las pueden cruzar los vehículos con el objeto de acceder a edificios u otros accesos. Las zonas de prioridad invertida se trata de calzadas donde la prioridad es para los peatones. La plataforma única es un vial compartido entre vehículos y peatones, con una sola rasante, en la que por definición la prioridad es para los peatones y se prohíbe el estacionamiento.

Pregunta 8: En el caso de actuaciones del llamado *Urbanismo táctico* o afectadas por una obra en la vía pública, donde habitualmente se restringe con mobiliario de diversa índole o con vallas el acceso de vehículos, se puede considerar que mientras existan estos elementos se puede hablar de calzada?

No.

Pregunta 9: Ara pasamos al Bloque correspondiente a los elementos que sí o no se pueden encontrar, inequívocamente, en una acera. Empezaremos preguntando: ¿es este en el caso del pavimento asfáltico entre bordillo y fachada o borde de solar o zona ajardinada o de parque?

Si.

Pregunta 10: ¿Se puede considerar como acera el caso del pavimento asfáltico entre bordillo y otro bordillo enfrentado?

No.

Pregunta 11: ¿Se puede considerar siempre como acera el caso que la planta esté pavimentada con pavimento granítico, de hormigón, *panot*, losas o losetas?

Si.

Pregunta 12: En relación con la anterior pregunta 7, ¿entonces la reserva para una licencia de vado para vehículos se puede considerar siempre acera?

No.

Pregunta 13: ¿Los vados de un paso de peatones señalizado siempre forman parte de la acera?

Si.

Pregunta 14: ¿Unas escaleras, entendidas como dos o más escalones consecutivos en un mismo contexto, se hallarán siempre en la acera?

Si.

Pregunta 15: ¿Un escalón único se encontrará siempre en la acera?

Si.

Pregunta 16: ¿Un árbol en un alcorque o zona ajardinada entre bordillo y fachada se encontrará siempre en la acera?

Si.

Pregunta 17: ¿Un árbol en un contexto diferente al del alcorque o zona ajardinada entre bordillo y fachada se hallará siempre en la acera?

Si.

Pregunta 18: ¿Un parterre se hallará siempre en la acera?

Si.

Pregunta 19: ¿Un banco o una silla se hallará siempre en la acera?

No.

Pregunta 20: ¿Un aparca-bicicletas se hallará siempre en la acera?

No.

Pregunta 21: ¿Un papelera se hallará siempre en la acera?

Si.

Pregunta 22: ¿La base de una farola o de un palo de servicios - telefonía o suministro eléctrico- se hallará siempre en la acera en el caso de tratarse de una vía urbana?

No.

Pregunta 23: ¿Una acera se hallará siempre en la acera?

No.

Pregunta 24: Un hito entre bordillo y fachada se hallará siempre en la acera?

No.

Pregunta 25: ¿Los buzones y armarios se hallarán siempre en la acera?

Si.

Pregunta 26: ¿Las jardineras se hallarán siempre en la acera?

No.

Pregunta 27: ¿La señalización vertical fijada en un palo o en otro mobiliario - con una farola- entre bordillo y fachada estará siempre en la acera en el caso de tratarse de una vía urbana?

No.

Pregunta 28: ¿La señalización horizontal que no se halle entre bordillo y fachada estará siempre en la acera?

No.

Pregunta 29: ¿Las tapas de registro de servicios - contadores y acometidas-, del alcantarillado y de los albañales ubicados entre bordillo y calzada formarán siempre parte de la acera?

No.

Pregunta 30: ¿Los sumideros que se ubiquen entre bordillo y fachada estarán siempre en la acera?

Si.

Pregunta 31: ¿Los embornales alineados con la *rigola* formen parte de la acera?

No.

Pregunta 32: ¿La *rigola* (cuneta) forma parte de la acera?

No.

Pregunta 33: ¿Los bordillos, ya sean de pavimento o metálicos, formarán siempre parte de la acera?

Si.

Pregunta 34: ¿Puede haber un espacio en la Vía pública que pueda considerarse como acera pero donde no exista bordillo alguno?

Si.

Pregunta 35: A continuación pasaremos al Bloque de definiciones del concepto de incidencia en una acera. Para empezar, ¿cuál sería la definición básica de una incidencia en el pavimento? ¿Podemos hablar también de *anomalías* en este contexto concreto?

Una incidencia en una acera es cualquier elemento en mal estado o que representa un riesgo para el correcto desarrollo del día a día, ya sea del propio pavimento de acera o de cualquier elemento urbano.

Pregunta 36: Intentaremos definir cuáles son los estados del pavimento de acera que justificarían programar una actuación de mantenimiento del mismo - arreglo o sustitución de las piezas-, tratando de obtener de este modo una definición por contraste de su estado que "sí fuese aceptable". Trataremos en todo momento de identificar categorías amplias a partir de ejemplos ilustrativos.

En este caso, ¿una acera donde se observen desniveles entre las piezas estaría en un estado aceptable?



Figura A.1: Pregunta 36 (Typeform).

No.

Pregunta 37: Un pavimento de acera que presente solamente pérdidas parciales de material o grietas en las piezas pero sin que estas parezcan estar también desencajadas o inestables, ¿entonces estaría en estado aceptable?




Figura A.2: Pregunta 37 (Typeform).

Si.

Pregunta 38: Un pavimento de acera que presente solamente manchas o sciedad incrustada,

¿estaría en estado aceptable?



Figura A.3: Pregunta 38 (Typeform).

Si.

Pregunta 39: Un pavimento de acera que represente, fruto de seu deterioramiento, un problema obvio para la accesibilidad, ¿estaría en un estado aceptable?



Figura A.4: Pregunta 39 (Typeform).

No.

Pregunta 40: Un pavimento de acera que esté levantado por las raíces de un árbol en un alcorque, ¿estaría en estado aceptable?



Figura A.5: Pregunta 40 (Typeform).

No.

Pregunta 41: Cuando una acera se ha modificado intencionadamente para adaptarse a las raíces visibles de un árbol (por ejemplo, con los *panots* recortados), ¿estaría en estado aceptable?



Figura A.6: Pregunta 41 (Typeform).

No.

Pregunta 42: Un pavimento de acera donde crezca vegetación entre las juntas o fisuras,

¿estaría en estado aceptable?



Figura A.7: Pregunta 42 (Typeform).

No.

Pregunta 43: Un pavimento de acera donde se observe un arreglo provisional con cemento, hormigón o asfalto y que solamente represente una deficiencia de carácter estético, ¿estaría en estado aceptable?




Figura A.8: Pregunta 43 (Typeform).

Si.

Pregunta 44: Un pavimento de acera donde se observe acumulación de agua o charcos,

¿estaría en estado aceptable?



Figura A.9: Pregunta 44 (Typeform).

No.

Pregunta 45: Un pavimento de acera donde observe una o más piezas rotas o volteadas, ¿se la puede considerar en estado aceptable?



Figura A.10: Pregunta 45 (Typeform).

No.

Pregunta 46: Un pavimento de acera donde se observen una o más piezas absentes, ¿se puede considerar en estado aceptable?



Figura A.11: Pregunta 46 (Typeform).

No.

Pregunta 47: Y para terminar: ¿creería oportuno establecer dos categorías de actuación diferenciadas? *Categoría A:* Actuaciones inmediatas (urgentes o a realizar durante las siguientes semanas); y *Categoría B:* actuaciones a largo plazo, a considerar solamente en grandes obras de reurbanización o renovación del pavimento en ese ámbito.

Sí, es preciso muy bien cuál actuación corresponde a una urgencia que requiere de una actuación inmediata, y cuáles no precisan de esta urgencia, las cuáles se pueden planificar con más rigor y posiblemente realizar actuaciones más globales a medio plazo.

Es muy habitual hallar aceras muy estrechas en mal estado, aunque la propuesta inicial pueda ser su reparación, muy frecuentemente requieren de una visión más global del barrio o del sector, y valorar la posibilidad de poder eliminar las aceras estrechas y poder ejecutar plataformas únicas, que a la vez mejoran la accesibilidad tanto a pe como con vehículo.

Anexo B

Figuras del análisis descriptivo del BIAA

En éste apartado se incluirán las Figuras relativas a las frecuencias y proporción de las clases etiquetadas en el BIAA correspondientes al capítulo 3.




Figura B.1: Frecuencias y proporción de la resolución de las imágenes una vez aplicado el recorte de preprocesamiento. Según A. Sarkis (Sarkis 2024, pág. 96), este es el metadato más relevante del *raw data* o datos sin anotar antes de su proceso de anotación.




Figura B.2: Distribución horaria de las imágenes desglosada por trimestres. Se ha optado por no tratar de establecer clasificaciones heurísticas en función de la hora de la salida y puesta de sol pues se aprecia que esta no reflejaría de forma adecuada las condiciones lumínicas de cada escena concreta. Sobre esta cuestión, ver también el posterior apartado 4.2.1.




Figura B.3: Treemap de la distribución geográfica de las imágenes capturadas (*raw data*) en el municipio de Barcelona. La concentración de muestras en el distrito de Horta-Guinardó refleja la disponibilidad para realizar recorridos pedestres con regularidad y la presencia de una alta diversidad de tipologías de pavimento en un mismo distrito, lo que permite capturar variabilidad funcional sin necesidad de cobertura geográfica uniforme.




Figura B.4: Frecuencias y proporción de las instancias anotadas en función de su clase etiquetada en los subconjuntos de entrenamiento y validación.




Figura B.5: Frecuencias y proporción de la resolución de imágenes en los subconjuntos de entrenamiento y validación.




Figura B.6: Proporción del área rasterizada - número de píxeles- por cada clase en los subconjuntos de entrenamiento y validación.

Anexo C

Figuras del análisis cualitativo de la comparación entre modelos

En éste apartado se incluirán las Figuras en las que se recoge el análisis cualitativo de los resultados del experimento correspondiente al apartado 4.1.



Figura C.1: Imágenes del BIAA segmentadas semánticamente por DeepLabV3+ entre las etiquetas *road* y *sidewalk* de Cityscapes. En los tres casos se puede apreciar como el modelo introduce el patrón de la calzada como clase predominante en el centro de la escena, aunque las aceras que se ajustan a su patrón sí se segmentan con mayor precisión (*inferior*). Obsérvese también como en el caso de la imagen superior el modelo solamente clasifica como acera la región de pixels inmediata a los peatones, independientemente de si se trata de una acera o calzada.



Figura C.2: Imágenes de los *benchmarks* BDD100K (*superior*), Cityscapes (*centro*) y Mapillary Vistas (*inferior*) segmentadas semánticamente con DeepLabV3+. Sólo en el caso de ejemplo de Cityscapes - originaria de su subconjunto de test- el modelo hace una segmentación alineada con significados humanos mientras que en los otros dos casos fuerza de nuevo el patrón de la calzada protagonizando la predicción de la escena.




Figura C.3: Imágenes del BIAA segmentadas semánticamente por HRNet entre las etiquetas *road* y *sidewalk* de Cityscapes. En los tres casos se puede apreciar como nuevamente el modelo introduce el patrón de la calzada como clase predominante en el centro de la escena, aunque las aceras que se ajustan a su patrón sí se segmentan con mayor precisión (*inferior*). En este caso, no se aprecia el fenómeno de asignación de la clase *sidewalk* a la región inmediata a todas las figuras humanas.



Figura C.4: Imágenes de los *benchmarks* BDD100K (*superior*), Cityscapes (*centro*) y Mapillary Vistas (*inferior*) segmentadas semánticamente con HRNet. Se aprecia una mejora en la predicción de la muestra de BDD100K al presentar esta algunas similitudes entre ambas clases *road* y *sidewalk* de Cityscapes, pues clasifica la calzada con una acera a su derecha y sin que el hecho de hallarse coches estacionados sobre la acera lo confunden al clasificarla como calzada como se observaba en la anterior Figura 15. En cambio, en el ejemplo de Mapillary Vistas el modelo aplica de nuevo el patrón típico de Cityscapes.




Figura C.5: Imágenes del BIAA segmentadas semánticamente por Mask2Former entre las etiquetas *road* y *sidewalk* de Cityscapes. En los tres casos se puede apreciar como el modelo también fuerza el patrón de la calzada como clase predominante en el centro de la escena. En este caso, se aprecia especialmente el fenómeno de asignación de la clase *sidewalk* a la región inmediata a las figuras humanas (*superior*), en este caso clasificando erróneamente toda una sección de calzada como acera.



Figura C.6: Imágenes de los *benchmarks* BDD100K (*superior*), Cityscapes (*centro*) y Mapillary Vistas (*inferior*) segmentadas semánticamente con Mask2Former. En este caso se aprecia una segmentación muy ajustada a dominio al presentar la escena de BDD100K algunas similitudes entre ambas clases *road* y *sidewalk* de Cityscapes. En cambio, en el ejemplo de Mapillary Vistas el modelo aplica de nuevo el patrón típico de Cityscapes y clasificando la sección de calzada donde está pintado el paso de peatones como una extensión de la acera más alejada del observador.




Figura C.7: Muestra del resultado de la segmentación por instancias por SAM en modo *Segment Everything* con: imagen de alta resolución y configuración por defecto (*izquierda superior*), imagen de alta resolución y configuración experimental (*derecha superior*), imagen con resolución reducida y configuración por defecto (*izquierda inferior*) e imagen con resolución reducida y configuración experimental (*derecha inferior*). Se aprecia una reducción de la sobresegmentación, 77 a solamente 8 y de 69 a solamente 8, respectivamente y especialmente de la que carece de significación humana o *human alignment*-. También se aprecia el mismo fenómeno al reducir la resolución de la imagen pero, especialmente, al aplicar la configuración experimental de los parámetros de SAM descrita en el apartado 3.2. Sin embargo, también se aprecia una pérdida de segmentaciones relevantes - como el bache en la acera- además de casos de subsegmentación en el caso de la cuneta o *rigola* cuando se reduce la resolución de la imagen.



Figura C.8: Segmentación por instancias de SAM en imágenes del BIAA con la parametrización experimental. SAM demuestra capacidad por predecir máscaras diferenciadas para piezas individuales o conjuntos de pavimentos de diversa tipología. En cambio, en el caso de la *imagen central* se observa que no reconoce las piezas de hormigón del alcorque en primer plano como máscara diferenciada e incluye en la misma máscara el bordillo con la acera adyacente. A su vez, en la *imagen inferior* se aprecia sobresegmentación con el *panot de cuatro círculos o de anillas*, subsegmentación del bordillo y confusión en una misma máscara de la *rigola* con el pavimento de la calzada. Todos estos errores tienden a sugerir que la anotación de SAM tiende a estar fuera del dominio de la vía pública de Barcelona y el área metropolitana.

Anexo D

Figuras del experimento del ajuste de DeepLabV3 con el BIAA

En éste apartado se incluirán las Figuras correspondientes al desarrollo de los entrenamientos de los cuatro experimentos del apartado 4.3.1 además de las Figuras correspondientes al análisis cualitativo de los resultados del experimento correspondiente al apartado 4.3.2.




Figura D.1: Desarrollo del entrenamiento con optimizador Adam y de 52 epochs de duración. De los cuatro entrenamientos, resulta significativo constatar que el mejor resultado también se obtuvo de forma más tardía, en la epoch 45.




Figura D.2: Desarrollo del entrenamiento con optimizador Adam y de 47 epochs de duración.




Figura D.3: Desarrollo del entrenamiento con optimizador Adam y de 31 epochs de duración.




Figura D.4: Desarrollo del entrenamiento con optimizador Adam y de 44 epochs de duración. Se constata que en los tres modelos subóptimos el mejor rendimiento se obtuvo entre los epochs 25 y 30 (ver también la Tabla 4.6).




Figura D.5: Escena donde se observa en primer plano una sección de acera con *panot* de 4 pastillas que presenta una deformación perpendicular que obstaculiza su accesibilidad; al fondo de la escena, cruzado el paso de peatones y también a la izquierda, la acera está pavimentada con asfalto. El modelo predice correctamente la acera modular y también la vegetación, el mobiliario y la mayoría de tapas de registro - excepto la del alcantarillado parcialmente oculto a la derecha, que confunde con un alcorque-, además de la cuneta allá donde es visible. En cambio, fracasa en clasificar tanto los bordillos como el pavimento asfáltico, que confunde sistemáticamente con la calzada. Llama la atención que, en cambio, sí tienda a clasificar correctamente en esa misma región de la escena los parterres, el arbolado y el mobiliario. También nótese el ciclista sobre la acera a la izquierda de la escena y que el modelo ignora, clasificando correctamente como acera y calzada las regiones correspondientes a la oclusión.




Figura D.6: Escena donde se observa un alcorque vacío o sin árbol con reborde metálico adyacente al bordillo, la cuneta y la calzada. Obsérvese que, mientras que la delimitación entre la calzada y la cuneta y, por otra parte, el alcorque y la acera es precisa, al fallar el modelo en clasificar correctamente el bordillo conduce a errores de clasificación en su región como también en la cuneta.




Figura D.7: Escena donde se observan diversos tipos de pavimento modular de la acera, un embornal para el drenaje y, a la izquierda, una sección de calzada también con pavimento modular. En este caso, el modelo falla al clasificar esta última región de la escena como calzada.




Figura D.8: Escena nocturna donde se aprecia un alcorque con árbol. El modelo clasifica con precisión la tapa de registro y el árbol, aunque muestra algunos errores al tratar de fijar la delimitación entre la región correspondiente a las piezas de hormigón del alcorque y el *panot* adyacente.




Figura D.9: Escena donde se observan dos motocicletas estacionadas sobre la acera, práctica tolerada en Barcelona y la mayoría de municipios del área metropolitana. En este caso, se observa una clasificación parcial de ambos objetos como acera modular y calzada, correspondiendo esta última a la región más alejada del bordillo y cuneta sí clasificados correctamente.




Figura D.10: Escena donde se observa un coche truncado y una moto estacionada sobre la acera. En el caso de la motocicleta, esta cuenta con las clases de bordillo y cuneta correctamente clasificados que actúan como separación de la región de pixels correspondiente a la calzada. En cambio, toda la región correspondiente al coche es clasificada como calzada, indistintamente del contexto.